RaBitQ：基于近似最近邻搜索理论误差界的高维向量量化方法

高建阳
jianyang.gao@ntu.edu.sg新加坡
南洋理工大学

程龙* c.long@ntu.edu.sg新加坡
南洋理工大学

arXiv:2405.12497v1 [cs. DB] 2024年5月21日

摘要

在高维欧氏空间中搜索近似最近邻（ANN）是一个关键问题。近年来，借助基于 SIMD 的快速实现技术，乘积量化（PQ）及其变体方法已能高效且精准地估算向量间的距离，并在内存内 ANN 搜索中取得了显著成功。尽管这些方法在实证中表现优异，但我们注意到它们缺乏理论误差界，且在某些真实世界数据集上会出现严重失效。基于此，我们提出一种名为 RaBitQ 的新型随机量化方法，该方法将D维向量量化为D位字符串。RaBitQ 不仅保证了严格的理论误差界，同时兼具优异的实证精度。此外，我们还提供了 RaBitQ 的高效实现方案，支持通过位运算或基于 SIMD 的运算来估算距离。在真实数据集上的大量实验证实：(1)本方法在精度与效率的权衡方面，相较 PQ 及其变体具有显著优势；(2)其实证性能与理论分析结果高度吻合。

ACM 参考文献格式：

Jianyang Gao 与 Cheng Long . 2018. RaBitQ：基于理论误差界对高维向量进行量化，用于近似最近邻搜索。收录于*《2024年国际数据管理会议论文集（SIGMOD 24）》*。ACM，美国纽约州纽约市，22页。https://doi.org/xxxxxxx.xxxxxxx

1 引言

在高维欧氏空间中搜索最近邻（NN）对于信息检索[60]、数据挖掘[16]以及推荐系统[77]等多种应用场景至关重要。然而，维度灾难[39, 90]导致在大规模向量数据库上执行精确最近邻查询在实际应用中难以实现，因其响应时间过长。为在耗时与精度之间取得平衡，研究人员常转而探索其放宽版本——即近似最近邻（ANN）搜索[18, 34, 37, 45, 65, 71]。

产品量化（PQ）及其变体是用于人工神经网络（ANN）[8, 34, 36, 45, 66–68, 83, 85, 95]的一类常用方法。这些方法目标是在查询阶段高效估算数据向量与查询向量之间的距离，从而筛选出一批候选向量列表；这些候选向量随后将根据精确距离重新排序，以查找最近邻（NN）。具体而言，在索引阶段中，该方法(1)构建一个量化码本；(2)为每个数据向量在码本中查找其最近向量，将其作为该向量的量化向量。该量化向量以简短的量化编码形式表示并存储（例如：量化后数据向量在码本中的标识符）。在查询阶段中，当接收到查询时，该方法(1)预先计算查询向量与码本中各向量之间的（平方）距离[1]；(2)对于每个数据向量，采用查询向量与其量化数据向量之间的距离（可通过查询预先计算的值获得）作为估算距离。近年来，借助基于SIMD的快速实现方案[4, 5]，PQ算法已在内存内ANN搜索领域取得显著成果[37, 43, 48]。尤其在众多真实世界数据集上，该方法均能高效且高精度地估算距离。尽管 PQ 及其变体在诸多真实世界数据集上取得了实证成功，但据我们所知，这些方法及其变体[8, 34,36, 45, 66–68, 83, 85, 95]均未针对估计距离提供理论误差界。其原因在于它们在以下两个环节均丧失了理论保证：(1) 码本构建环节；(2) 距离估计环节。码本构建：这些方法通常通过针对启发式目标函数近似求解优化问题来构建码本——例如 PQ 方法对数据向量的子片段进行 K-Means 聚类，并将聚类质心的乘积集合用作码本。然而，由于其启发式特性，往往难以从理论角度分析其结果（例如，目前尚未在“数据向量与其码本中最近向量（即其量化向量）之间的距离”问题上获得理论性结论）。距离估计：这些方法采用量化数据向量与查询向量之间的距离来估计原始数据向量与查询向量之间的距离，即直接将量化数据向量作为计算距离时的数据向量使用。尽管这一观点看似直观，但它并未提供关于近似误差的理论界值。缺乏理论误差界值的这一事实表明，当这些方法被部署于真实世界系统，以处理其此前未参与测试的新数据集及查询时，它们仍可能在任何时刻——无论是中度或重度——出现不可预测的失效。事实上，此类失效现象已在被广泛用于人工神经网络（ANN）检索性能评估的公开真实世界数据集上得到验证。例如，在 MSong 数据集上，PQ 算法（采用基于快速 SIMD 的实现[4, 5]）在查询向量与数据向量间估计距离上，其平均相对误差超过 50%，这会导致 ANN 检索的召回率急剧下

*程龙为通讯作者。

对于本作品全部或部分内容，若出于个人或课堂教学用途而制作数字副本或纸质副本，只要未以营利或商业目的制作或分发此类副本，且副本首页注明本声明及完整引用信息，即可免费获取使用许可。若本作品中的部分内容由 ACM 以外的主体所有，则须遵守相关版权规定。允许在注明出处的前提下进行摘要提取；否则，如需复制、重新发布、上传至服务器或向邮件列表重新分发，均需事先获得特定许可及/或支付相应费用。许可申请请发送至 permissions@acm.org。

SIGMOD 24,2024年6月8日–15日，智利圣地亚哥
© 2018 美国计算机协会。
ACM ISBN 978-1-4503-XXXX-X/18/06…$15.00
https://doi.org/XXXXXXX.XXXXXXX

[1]除非另有说明，此处“距离”均指距离的平方。

降（例如，即使应用重排序处理，其召回率仍不超过 60%，如第5.2.3节所示）。

本文提出了一种新的量化方法，该方法[2]该方法对距离进行了无偏估计，并获得了精确的理论误差界。这一成果得益于在码本构建与距离估计两个模块中精心整合的设计。码本构建：首先对数据向量进行归一化处理，使其位于D维空间中的单位超球面上；随后通过以下步骤构建码本：(1) 构造一组2^D*二值*向量，其坐标分量取值为$-1/\sqrt{D}$或$+1/\sqrt{D}$（即该集合由超立方体的顶点构成，这些顶点均匀分布在单位超球面上）以及(2)通过将每个双值向量与一个*随机正交矩阵*相乘，对双值向量进行随机旋转[3]（即执行一种Johnson-Lindenstrauss变换[49]，简称 JLT）。对于每个数据向量，从码本中选取其最近向量作为量化向量。由于每个量化向量均为一个旋转后的D维双值向量，我们将其量化码表示为长度为D的比特串，其中0和1分别表示两个不同值。码本构建的基本原理在于其具有清晰的几何解释（即码本中的向量是一组在单位超球面上随机旋转的向量），从而能够显式地分析数据向量、其量化向量与查询向量之间的几何关系。距离估计：我们充分利用上述几何关系，精心设计了一个用于估计数据向量与查询向量之间距离的估计器。我们利用关于 JLT 的丰富理论工具[28, 52, 82]，证明了该估计量是*无偏的*，并且具有精确的概率误差界。这与 PQ 及其变体形成鲜明对比，后者仅将量化后的向量视为估计距离的数据向量，这种做法*存在偏差*，且*无法提供*理论误差界。我们将这种使用随机变换后的双值向量来量化数据向量的新量化方法命名为 RaBitQ。与 PQ 及其变体相比，RaBitQ 不仅能在理论上提供误差界，还能以约一半的量化码长，用更小的经验误差估计距离（这一点已在第5.2.1节所示的所有测试数据集上得到验证）。

我们进一步介绍了两种高效实现方案，用于计算 RaBitQ 距离估计量的值：一种适用于*单个*数据向量，另一种适用于一*批*数据向量。对于前者，我们的实现基于简单的位运算——须知我们的量化码均为位字符串。在达到相同精度条件下（如第5.2.1节所示），本实现的平均速度较原始 PQ 实现快约 3 倍，而原始实现需依赖内存中的查找表。需要注意的是，对于单个数据向量，PQ 的基于 SIMD 的实现方案[4, 5]并不适用，因其需要将量化码打包成一批，并精细调整其布局。对于后者，则可无缝采用快速 SIMD 实现方案[4, 5]中的相同策略，从而在使用相同长度量化码时，获得与现有 PQ 基于 SIMD 的实现方案相当的效率。

- 在此情况下，本方法可提供更精确的估计值。

[2]该误差界在以下意义上是紧的：它实现了[3]中所示的渐近最优性。详细讨论可参阅第3.2.2节。

[3]我们注意到，我们并未显式地实现码本，而是以概念化的方式维护该码本，这与 PQ 等现有量化方法的做法一致。

距离如前所述。表1展示了 RaBitQ 与 PQ 及其变体之间的部分对比结果。

我们将主要研究成果总结如下。

(1) 我们提出了一种新的量化方法——RaBitQ。(1)该方法通过随机变换二值向量来构建码本；(2)该方法设计了一种*无偏*距离估计器，并具备精确的概率误差界。

(2) 本文介绍了计算 RaBitQ 距离估计量的高效实现方案。在针对单个数据向量进行距离估计时，本实现方案相较于 PQ 及其变体的对应实现方案具有更高效率；而在针对具有相近长度量化码的批量数据向量进行距离估计时，其运行速度则与上述方案相当。

(3) 我们在真实世界数据集上进行了大量实验，实验结果表明：(1)即使 RaBitQ 使用的编码长度仅为 PQ（及其变体）的一半，其估计距离的准确性仍高于 PQ（及其变体）——这暗示当两种方法使用相近长度的编码时，准确性差距将进一步扩大；(2)RaBitQ 在所有测试数据集上均稳定且高效地运行，包括部分 PQ（及其变体）无法成功运行的数据集——这一结果与理论分析高度吻合；(3)对于内存式人工神经网络而言，RaBitQ 在时间复杂度与准确性的权衡表现上，在所有测试数据集上均显著优于 PQ（及其变体）；(4)RaBitQ 的实际性能与理论分析结果高度一致。

本文其余部分结构如下：第2节介绍ANN搜索与PQ及其变体；第3节阐述本文提出的RaBitQ方法；第4节展示RaBitQ在内存ANN搜索中的应用；第5节基于真实世界数据集开展广泛实验研究；第6节讨论相关研究工作；第7节给出结论与讨论。

2 ANN 查询与量化

ANN查询。假设我们在D维欧氏空间中拥有一个包含N个数据向量的数据库。近似最近邻（ANN）搜索查询的目标是：针对给定的查询向量$\mathbf{q}$，从数据库中检索出最近的向量。该问题通常被扩展为检索K个最近邻。为便于阐述，我们在算法描述中假定K=1，而所有提出的技术均可轻松适配至一般情形下的K。本文聚焦内存式ANN研究，其前提是所有原始数据向量与索引均可驻存于主内存中[4–6, 30, 32, 58, 65]。

产品量化。产品量化（PQ）及其变体是用于人工神经网络（ANN）[8, 34, 36, 45, 66–68, 83, 85, 95]的一类常用方法（关于更广泛量化方法的讨论，请参阅第6节）。对于查询向量与数据向量，这些方法旨在基于预先计算的短量化码，高效估算二者间的距离。具体而言，PQ 算法将D维向量划分为M个子片段（每个子片段具有D/M维）；对每个子片段，该算法在D/M维向量上执行 K-Means 聚类，获得 2^k个聚类簇，随后将这些簇的质心取作子码本，其中k为可调节参数，用于控制子码本的规模。

表 1：RaBitQ 与 PQ 及其变体之间的对比。更多★符号表示更高的效率。

	RaBitQ（新版）	PQ 及其变体
编码手册	随机变换的双值向量。	子码本之笛卡尔积。
量化代码	一个比特串。	一个由 4 位/8 位无符号整数组成的序列。
距离估计器	无偏，且可提供精确的误差界。	存在偏差，且不提供误差界。
实施（单次）	位运算。★★	在 RAM 中查找表。★
实施（批量）	基于 SIMD 的快速运算。★★★	基于 SIMD 的快速运算。★★★

(默认k=8)。PQ的码本由各子区段的子码本进行笛卡尔积构成，其大小为$(2k)^M$。相应地，每个量化码均可表示为一个长度为M、包含k个无符号整数的序列。在查询阶段，采用非对称距离计算来估计距离[45]。具体而言，当出现查询时，PQ会对每个子码本预处理M个查找表(LUT)。第i个LUT包含2^k个数值，这些数值表示第i个子码本中的向量与查询向量的第i个子区段之间的平方距离。对于给定的量化码，PQ通过M次查询并累加LUT中的数值，即可计算出估计距离。

最近，[4,5] 本文提出了一种基于SIMD的PQ算法快速实现方案（简称PQ Fast Scan，简称PQx4fs）。该方案显著提升了查找与累加操作的速度，使PQ算法成为众多主流内存式ANN搜索库中的重要组成部分，例如Meta公司的Faiss[48]、Google公司的ScaNN[37]以及Yahoo日本公司的 NGT -QG[43]。与原始PQ实现方案依赖RAM中的查找表不同，[4, 5]本方案将查找表驻留在SIMD寄存器中，并利用SIMD洗牌指令进行查找。为实现这一目标，本方法对PQ算法进行了若干改进：首先，为使查找表适配AVX2 256位寄存器，将原始设置k=8调整为k=4，从而确保每个查找表中仅包含24个浮点数；进一步将查找表中的数值量化为8位无符号整数，使得单个查找表仅占用128位（2^4×8）存储空间。如此一来，单个AVX2 256位寄存器即可容纳两个查找表；其次，为实现高效查找，本方案将每32个量化码打包为一批，并重新组织其布局。在此情况下，一系列操作可一次性估算 32 个数据向量的距离。若无特别说明，默认情况下我们将“PQ”指代为 PQx4fs，因为若缺乏基于快速 SIMD 的实现，PQ 在内存内人工神经网络搜索中的效率将显著降低[4, 5]（参见第5.2.1节）。

然而，PQ 及其变体均未对估计距离的误差提供理论误差界[8, 34, 36, 45, 66–68, 83, 85, 95]，如第1节所述。事实上，我们发现 PQ 的精度可能严重不足（参见第5.2.3节），例如在 MSong 数据集上，即使应用重排序，PQ 也无法达到 ≥ 60% 的召回率。我们注意到，局部敏感哈希（LSH）是一类方法，它们提供了严格的理论保证[18, 38, 39, 78–80]。然而，正如广泛报道的那样[6, 58, 85]，这些方法几乎无法取得具有竞争力的实证性能。此外，它们的保证是针对c次近似 NN 查询的精度。具体而言，LSH 保证以高概率返回一个与查询点距离至多为固定半径r的 (1 +c) 倍的数据向量（若存在此类数据向量）。

表 2：符号说明。

符号说明	定义
$\mathbf{或}$，$\mathbf{qr}$	原始数据与查询向量。
$\mathbf{o}, \mathbf{q}$	归一化数据与查询向量。
C, C_{rand}	量化码本及其随机化版本。
P	一个随机正交变换矩阵。C语言中的代码$P\ \bar{}\mathbf{x}$表
$\bar{\mathbf{x}}$	
$\bar{\mathbf{o}}$	示$\mathbf{o}$的量化向量。Crand 文献中$\mathbf{o}$的量化向量，
$\bar{\mathbf{x}}_b$	即$\bar{}\mathbf{o}=P\ \bar{}\mathbf{x}$。将$\mathbf{o}$量化为$D$位字符串。逆变换后的
$\mathbf{q}'$	
$\bar{\mathbf{q}}$	查询向量，即$P^{-1}\mathbf{q}$。以及$\mathbf{q}$的量化查询向量。
$\bar{\mathbf{q}}_u$	$\bar{}\mathbf{q}$的无符号整数表示。

其与查询点之间的距离在半径r内的所有数据点。由于松弛因子c的存在，可能存在多个满足该条件的数据点。仅保证返回其中*任意*一个数据点，并不能有助于提升ANN搜索的召回率。相反，对距离估计值的保证，则有助于判断是否需要对某个数据向量进行重新排序，从而获得高召回率（参见第4节）。

3 RABITQ 法

在本节中，我们将详细介绍 RaBitQ 的相关内容。在3.1节中，我们阐述 RaBitQ 的索引阶段：对数据向量进行归一化处理（3.1.1节）、构建码本（3.1.2节），以及计算数据向量的量化向量（3.1.3节）。在3.2节中，我们介绍 RaBitQ 的距离估计器——该估计器具有无偏性，并能提供严格的理论误差界。在3.3节中，我们演示如何高效计算该估计器的值。在3.4节中，我们对 RaBitQ 方法进行总结。表2列出了常用符号及其定义。

3.1 使用 RaBitQ 对数据向量进行量子化

*3. 1.1 通过归一化将原始向量转换为单位向量。*我们注意到，若直接为原始数据向量构建码本，则难以满足理论误差界的要求——因为欧氏空间是*无界的*，且原始数据向量可能出现在这个无限大的空间中的任意位置。为解决这一问题，一个自然思路是将原始向量归一化为*单位*向量。具体而言，令$\mathbf{c}$为原始数据向量的质心，我们将原始数据向量$\mathbf{或}$归一化为$\mathbf{o}:=_{||\mathbf{o}_r\cdot\mathbf{r}_i_\epsilon\epsilon||}$。类似地，

我们将原始查询向量$\mathbf{q}_r$（在查询阶段输入时）归一化为$\mathbf{q}:=_{||\mathbf{q}\cdot\mathbf{r}_\epsilon\epsilon||}$。以下表达式建立了原始向量（即我们的目标）与归一化向量内积之间的距离。

$$\|\mathbf{o}_r - \mathbf{q}_r\|^2 = \|(\mathbf{o}_r - \mathbf{c}) - (\mathbf{q}_r - \mathbf{c})\|^2 \tag{1}$$

$$= 聂\mathbf{或}_\mathbf{c}聂^2 + 聂\mathbf{qr}_\mathbf{c}聂^2 - 2 \cdot 聂\mathbf{或}_\mathbf{c}聂 \cdot 聂\mathbf{qr}_\mathbf{c}聂 \cdot \langle \mathbf{q}, \mathbf{o} \rangle$$

(2) 我们注意到，聂**或_c**聂 表示数据向量到质心的距离，可在索引阶段预先计算；聂**qr_c**聂 表示查询向量到质心的距离，可在查询阶段计算，且其计算成本可由所有数据向量共享。因此，基于公式(2)，计算聂**或_qr**聂^{2}的问题可转化为计算两个单位向量〈**q**，**o**〉的内积。实践中，我们可先对数据向量进行聚类（例如采用K均值聚类），随后基于各簇的质心对簇内数据向量单独进行归一化处理；对于同一簇内的数据向量，则基于对应簇的质心对查询向量进行归一化。通过这种方式，归一化后的数据向量有望在单位超球面上均匀分布，从而在某种程度上消除数据（若存在）的偏态性。为便于表述，在后续内容中，除非另有说明，文中提及的"数据向量"与"查询向量"均指其对应的单位向量。基于此转换，我们接下来将聚焦于估计这两个单位向量的内积，即〈**q**，**o**〉。

3.1.2 码本构建。如第3.1.1节所述，由于归一化处理，数据向量在某种程度上应在单位超球面上均匀分布。基于直观判断，我们的码本也应在单位超球面上均匀分布。为此，现给出以下码本的一种自然构建方法。

$$C := \left\{+\frac{1}{\sqrt{D}}, -\frac{1}{\sqrt{D}}\right\}^D \tag{3}$$

可以轻易验证：C 中的向量均为单位向量，且码本的大小为 |C| = 2^D。

然而，这种构造可能会有利于某些特定向量，而对其他向量则表现不佳。例如，对于数据向量 (1/$\sqrt{D}$，…，1/$\sqrt{D}$)，其量化后的数据向量（即与数据向量最接近的 C 中的向量）为 (1/$\sqrt{D}$，…，1/$\sqrt{D}$)，且其与量化数据向量的平方距离为 0。相比之下，对于向量 (1,0，…，0)，其量化数据向量同样为 (1/$\sqrt{D}$，…，1/$\sqrt{D}$)，且其与量化数据向量的平方距离等于 2_2/$\sqrt{D}$。为解决这一问题，我们在码本中引入随机性。具体而言，令P为一个随机正交矩阵。我们建议将变换P应用于码本（这是 Johnson-Lindenstrauss 变换[49]的一种形式）。最终的码本如下所示。

$$C_{rand} := \{P\mathbf{x} | \mathbf{x} \in C\} \tag{4}$$

从几何角度来看，该变换仅对码本进行旋转，因为矩阵P是正交矩阵，因此 Crand 中的向量仍为单位向量。此外，该旋转是从该空间中"所有可能的旋转"中均匀采样的。因此，对于码本 C 中的任一单位向量，其被旋转至单位超球面上任意位置的概率均相等。这一步骤从而消除了确定性码本 C 对特定向量的偏好性。

我们注意到，为了构建 Crand 码本，我们仅需采样一个随机变换矩阵P；而为了存储该 Crand 码本，我们仅需物理存储已采样的P，而无需存储所有变换后的向量。通过此操作构建的码本，相较于 PQ 及其变体方案中依赖近似求解优化问题的对应码本，其结构要简单得多。

3. 1.3 数据向量的量化编码计算。基于已构建的码本，下一步是对每个数据向量从 Crand 中寻找其最近向量作为该向量的量化表示。对于*单位*向量**o**，寻找其最近向量等价于寻找与该向量内积最大的向量。设$P\,\bar{\mathbf{x}} \in$Crand 为量化后的数据向量（其中$\bar{\mathbf{x}} \in$C）。以下公式可严格阐释这一原理。

$$\bar{\mathbf{x}} = \arg\min_{\mathbf{x}\in C} \|\mathbf{o} - P\mathbf{x}\|^2 \tag{5}$$

$$= \arg\min_{\mathbf{x}\in C} (\|\mathbf{o}\|^2 + \|P\mathbf{x}\|^2 - 2\langle \mathbf{o}, P\mathbf{x}\rangle) \tag{6}$$

$$= \arg\min_{\mathbf{x}\in C} (2 - 2\langle \mathbf{o}, P\mathbf{x}\rangle) = \arg\max_{\mathbf{x}\in C} \langle \mathbf{o}, P\mathbf{x}\rangle \tag{7}$$

公式（5）基于量化数据向量的定义。公式（6）源于基础线性代数运算。公式（7）则是因为$P\mathbf{x}$与**o**均为单位向量。然而，根据公式（7），若通过物理变换庞大的码本并借助枚举法寻找最近向量来获取量化数据向量，其计算成本将极高。我们注意到内积对正交变换（即旋转）具有不变性。因此，我们无需变换庞大的码本，而是对数据向量**o**进行*逆*变换。以下表达式将正式阐述这一思路。

$$\langle \mathbf{o}, P\mathbf{x}\rangle = \left\langle P^{-1}\mathbf{o}, P^{-1}P\mathbf{x}\right\rangle = \left\langle P^{-1}\mathbf{o}, \mathbf{x}\right\rangle \tag{8}$$

回想一下 x ∈ C are ±1/$\sqrt{}$ 的各元素。$\bar{}D$。为最大化内积，我们只需选取满足各分量符号与P^{-1}**o**一致的$\bar{\mathbf{x}} \in$ C。此时，$P\,\bar{\mathbf{x}}$即为量化后的数据向量。

综上所述，为从Crand方法中获取数据向量**o**的最接近向量，我们可以利用P^{-1}对**o**进行逆变换，并将各分量的符号记录为D位字符串$\bar{\mathbf{x}}\mathbf{b} \in \{0,1\}^D$。我们将此存储的二进制字符串$\bar{\mathbf{x}}\mathbf{b}$称为*量化码*，该码可用于重构量化后的向量$\bar{\mathbf{x}}$.令$\mathbf{1}_D$表示所有分量均为1的$D$维向量。$\bar{\mathbf{x}}\mathbf{b}$与$\bar{\mathbf{x}}$的关系式为$\bar{\mathbf{x}}$= (2 $\bar{\mathbf{x}}\mathbf{b}$_$1_D$)/$\sqrt{D}$，即当第$i$个坐标分量$\bar{\mathbf{x}}\mathbf{b}[i]$ = 1时，有$\bar{\mathbf{x}}[i]$ = 1/$\sqrt{D}$；而当$\bar{\mathbf{x}}\mathbf{b}[i]$ = 0时，有$\bar{\mathbf{x}}[i]$ = -1/$\sqrt{D}$。为便于表述，我们将量化后的数据向量记为$\bar{\mathbf{o}}$:=$P\,\bar{\mathbf{x}}$。

迄今为止，我们已经完成了索引阶段的预处理工作。需要指出的是，索引阶段的时间开销对于我们的方法而言并非瓶颈，这与PQ及 OPQ（PQ的一种常用变体）[34]的情况相同。例如，在包含一百万个960维向量的GIST数据集上，使用CPU上的32个线程时，我们的方法、PQ及 OPQ 分别耗时117秒、105秒和291秒。这些方法的空间复杂度对于内存ANN而言同样不是瓶颈，因为空间消耗主要源于存储原始向量的空间需求。作为对比，每个原始向量占用32位比特（即D个浮点数）。我们的方法默认每个量化编码占用D位比特；而PQ与 OPQ 默认每个量化编码占用2D位比特（即M=D/2），如[25, 37]所述，这一数值远小于存储原始向量的所需空间。

3.2 构建无偏估计量

回顾可知，计算**或_qr**^{2}的问题可转化为计算两个单位向量〈**o**，**q**〉的内积问题。本节中，我们引入一个关于〈**o**，**q**〉的无偏估计量。与PQ及其变体方法——后者仅将量化后的数据向量直接用

作距离估计的数据向量，且缺乏理论误差界——不同，我们首先显式推导了以下两者间的关系：〈o，q〉与〈o，q〉见第 3.2.1 节。随后，我们基于推导出的关系式，为〈o，q〉构造一个无偏估计量，并在第3.2.2节中给出其严格误差界。

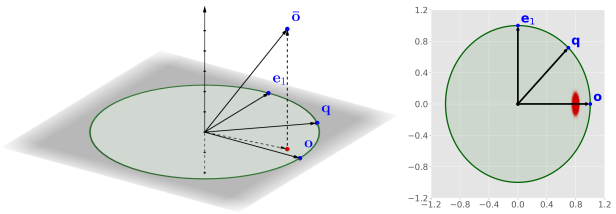


图 1：各向量间的几何关系。

3.2.1 分析〈o，q〉*与*〈ō，q〉。我们注意到〈o，q〉与〈ō，q〉仅取决于……的投影ō 在由o与q张成的二维子空间上，如图1左图所示。对于该分量ō 由于该向量与子空间正交，因此它对内积〈 没有影响。ō，q〉。以下引理给出了具体结果，其证明可参阅技术报告[33]。

引理 3.1（几何关系）。*设*o、q*及* ō *取任意三个单位向量。当*o*与*q*共线时（即*o=q*或*o=_q*），我们有*

$$\langle \bar{o}, q\rangle = \langle \bar{o}, o\rangle \cdot \langle o, q\rangle \tag{9}$$

*当*o*与*q*不共线时，我们有*

$$\langle \bar{o}, q\rangle = \langle \bar{o}, o\rangle \cdot \langle o, q\rangle + \langle \bar{o}, e_1\rangle \cdot \sqrt{1-\langle o, q\rangle^2} \tag{10}$$

其中e_1*是* q*–*〈q，o〉o*的归一化至范数为1的形式，即*$e_1 := \frac{q - \langle q, o\rangle o}{\|q - \langle q, o\rangle o\|}$。*我们注意到*o ⊥ e_1*（因为*〈o，e_1〉=0），*且*$\|e_1\| = 1$。

回顾一下，我们的目标是估计〈o，q〉。若我们能精确获知除〈o，q〉之外所有变量的取值，则可通过求解方程（9）与（10）来计算〈o，q〉的精确值。特别地，在方程（9）与（10）中，〈ōo〉表示量化数据向量与数据向量之间的内积。其值可在索引阶段预先计算得出。〈ōq〉表示量化数据向量与查询向量之间的内积。其值可在查询阶段高效计算（我们将在第3.3节中详述具体高效计算方法）。因此，当o与q共线时，可通过求解方程(9)精确计算出〈o，q〉的值，即〈o，q〉=$\frac{\langle \bar{o}, q\rangle}{\langle \bar{o}, o\rangle}$.

当o与q不共线时（这种情况更为常见），为了精确求解方程（10），我们需要已知〈 的值ō，e_1〉。然而，由于e_1同时依赖于o与q（而后者可根据其定义可知，〈o，e_1〉既不能在索引阶段预先计算（因为它依赖于q），也无法在查询阶段不访问o的情况下高效计算。

我们注意到，尽管我们无法高效地计算出〈 的精确值ō，e_1〉[4]，鉴于其随机特性ō，我们明确知晓其分布。具体而言，回顾一下：我们已采样一个随机正交矩阵*P*，将其作用于码本 C，并生成一个*随机化*码本 Cr。ō 它是从 Crand 的随机码本中选取的一个向量，因此它是一个随机向量。〈ō，o〉以及〈o，e_1〉对应于随机向量o在两个固定方向上的投影（即这两个方向分别为o与e_1，且满足o ⊥ e_1）。因此，它们是相互相关的随机变量。

我们对随机变量的分布进行了严谨分析。分析的核心结论简要总结如下，而详细阐述与证明则因篇幅限制保留于技术报告[33]中。具体而言，我们的分析表明：当*D*的取值范围为10^2至10^6时，恒有〈ōo〉的期望值[5]约为 0.8，且〈ōe_1〉的期望值恰好为 0。这进一步表明，以高概率，这些随机变量与其期望值的偏差不会超过$\Omega(1/\sqrt{D})$。该结论定量地揭示了这些随机变量围绕其期望值聚集的程度，此结果后续将用于分析我们估计量的误差界。为实证验证上述分析，我们在 128 维空间中，针对一对固定参数o、q，对随机正交矩阵*P*进行了 105 次重复且独立的采样。图1的右侧子图直观展示了上述矩阵的投影结果。ō 在由o与q张成的二维空间中，结合红色点云（每个点代表一个点的投影）ō 基于一个采样随机矩阵*P*）。特别地，〈ōo〉（x 轴）被显示集中在 0.8 附近。〈ōe_1〉（y 轴方向）呈集中分布，并关于原点对称分布，这完美地验证了我们的理论分析。

3.2.2 构建〈o，q〉的无偏估计量。基于对公式（9）的分析，当o，q共线时，〈o，q〉可通过〈o，q〉= 显式求解。$\frac{\langle \bar{o}, q\rangle}{\langle \bar{o}, o\rangle}$因此，可以自然地推测：当o与q不共线时，$\frac{\langle \bar{o}, q\rangle}{\langle \bar{o}, o\rangle}$它也应成为〈o，q〉的一个良好估计量。因此，我们由此推导出如下结论。

$$\frac{\langle \bar{o}, q\rangle}{\langle \bar{o}, o\rangle} = \frac{\langle \bar{o}, o\rangle \cdot \langle o, q\rangle + \langle \bar{o}, e_1\rangle \cdot \sqrt{1-\langle o, q\rangle^2}}{\langle \bar{o}, o\rangle} \tag{11}$$

$$= \langle o, q\rangle + \sqrt{1-\langle o, q\rangle^2} \cdot \frac{\langle \bar{o}, e_1\rangle}{\langle \bar{o}, o\rangle} \tag{12}$$

其中，公式（11）由公式（10）推导得出，且公式（12）可简化为公式（11）。我们注意到，公式（12）中的最后一项可视为该估计量的误差项。回顾我们之前的推导，如第 3.2.1 节所述，〈o，o〉的集中值集中在 0.8 附近。〈o，e_1〉的期望值为 0，且同样具有集中性。这表明误差项的期望值为 0，并且由于集中性作用，其值不会显著偏离 0。以下定理给出了具体结果，严格证明可参阅技术报告[33]。

定理 3.2（估计量）。*其无偏性由以下公式给出：*

$$\mathbb{E}\left[\frac{\langle \bar{o}, q\rangle}{\langle \bar{o}, o\rangle}\right] = \langle o, q\rangle \tag{13}$$

[4]特别是，当我们说“计算随机变量的‘值’”时，是指基于某个抽样分布*p*来计算该随机变量的*观测*值。

[5]精确期望值为 $\mathbb{E}[\langle \bar{o}, o\rangle] = \sqrt{\frac{D}{\pi}} \frac{\Gamma(\frac{D}{2})}{\Gamma(\frac{D-1}{2})}$ 其中 $\Gamma(\cdot)$ 为伽马函数。当$D \in [10^2, 10^6]$时，期望值范围为 0.798 至 0.800。

估计量的误差界如下所示：

$$\mathbb{P}\left\{\left|\frac{\langle\bar{\mathbf{o}},\mathbf{q}\rangle}{\langle\bar{\mathbf{o}},\mathbf{o}\rangle}-\langle\mathbf{o},\mathbf{q}\rangle\right|>\sqrt{\frac{1-\langle\bar{\mathbf{o}},\mathbf{o}\rangle^2}{\langle\bar{\mathbf{o}},\mathbf{o}\rangle^2}}\cdot\frac{\epsilon_0}{\sqrt{D-1}}\right\}\leq 2e^{-c_0\epsilon_0^2} \quad (14)$$

其中ϵ_0是控制失效概率的参数，c_0为常数因子。误差界可简洁地表示为

$$\left|\frac{\langle\bar{\mathbf{o}},\mathbf{q}\rangle}{\langle\bar{\mathbf{o}},\mathbf{o}\rangle}-\langle\mathbf{o},\mathbf{q}\rangle\right|=O\left(\frac{1}{\sqrt{D}}\right)\ with\ high\ probability \quad (15)$$

根据公式（2）与（13），〈**o**，**q**〉的无偏估计量可进一步推导出原始数据与查询向量间平方距离的无偏估计量。我们在第5.2.6节中提供了关于该无偏性的实证验证。此外，需要强调的是：基于类似分析，另一种估计量〈**o**，**q**〉≈〈¯**o**，**q**〉——即简单地将量化后的数据向量直接视作原始数据向量（如PQ算法所采用）——可被轻易证明具有*偏差*。

公式（14）给出了我们估计量的误差界。特别地，它给出了一个 $1_{2\exp(\langle\sp_2>c_0 E_{20}\rangle)}$ 置信区间。

$$\frac{\langle\bar{\mathbf{o}},\mathbf{q}\rangle}{\langle\bar{\mathbf{o}},\mathbf{o}\rangle}\pm\sqrt{\frac{1-\langle\bar{\mathbf{o}},\mathbf{o}\rangle^2}{\langle\bar{\mathbf{o}},\mathbf{o}\rangle^2}}\cdot\frac{\epsilon_0}{\sqrt{D-1}} \quad (16)$$

我们注意到，失效概率（即置信区间未能覆盖真实值〈**o**，**q**〉的概率）为 2 exp(− c_0 *E20*)。该概率关于ϵ_0呈二次指数衰减趋势，且衰减速度极快；而置信区间的长度则关于*E0*呈线性增长。因此，当ϵ_0=Θ(√log(1/δ)))时，失效概率至多不超过δ，这表明较短的置信区间可对应更高的置信水平。实践中，为追求近乎完美的置信度，ϵ_0被固定为1.9（实证验证研究详见5.2.4节）。需注意〈¯**o**，**o**〉的取值集中分布于0.8附近。基于ϵ_0与〈¯**o**，**o**〉的取值，误差界可进一步简洁地表述为公式(15)，即该公式保证误差界为*O*(1/√D)。根据一项近期理论研究[3]，对于*D*维向量（其编码长度为*D*比特），从理论上讲，任何方法*均不可能*提供比*O*(1/√D)更紧的误差界（将失败概率视为常数）。因此，公式（15）表明RaBitQ的误差界是紧的，即该方法达到了渐近最优性。该误差界后续将用于人工神经网络搜索，以判断数据向量是否需要重新排序（参见第4节）。

此外，我们注意到 RaBitQ 提供了一种加法形式的误差界[3]（即绝对误差）。当数据向量经过良好归一化时（如第3.1.1节所述，我们对数据向量进行了归一化处理），该误差界可进一步转化为乘法形式[41]（即相对误差）。详细讨论已收录于技术报告[33]中，因其基于数据向量已充分归一化的假设。需注意的是，本文提出的其余所有理论结果均不依赖任何关于数据的假设——即加法误差界对任意数据分布均成立。在本研究中，我们采用一种简单且自然的归一化方法（即使用 IVF 的质心进行归一化，具体方法将在第4节介绍）来实例化我们的量化方案，而关于归一化步骤本身的系统性探索尚待深入展开。我们将把对归一化问题的严格研究列为未来工作方向。

3.3 高效计算估计量

请记住$\frac{\langle\bar{\mathbf{o}},\mathbf{q}\rangle}{\langle\bar{\mathbf{o}},\mathbf{o}\rangle}$是该估计量。由于〈¯**o**，**o**〉已在索引阶段预先计算完成，剩余问题便是高效计算〈¯**o**，**q**〉的值。为便于表述，我们将P^{-1}**q**记作**q**。参照第3.1.3节中的处理方法，为计算〈¯**o**，**q**〉，可先计算〈¯**x**，**q**，〉，其验证过程如下。

$$\langle\bar{\mathbf{o}},\mathbf{q}\rangle=\langle P\bar{\mathbf{x}},\mathbf{q}\rangle=\left\langle P^{-1}P\bar{\mathbf{x}},P^{-1}\mathbf{q}\right\rangle=\left\langle\bar{\mathbf{x}},\mathbf{q}'\right\rangle \quad (17)$$

*3.3.1 对变换后的查询向量进行量化。*回顾可知，¯**x**是一个二值向量，其元素为 ±1/√D。如第3.1.3节所述，该向量被表示并存储为二进制量化码¯**xb**。**q**是一个实值向量，其元素通常用浮点数表示（简称为 float）。需要指出的是，在本方法中，使用浮点数来表示**q**的元素实属过度设计。具体而言，本方法采用$\frac{\langle\bar{\mathbf{o}},\mathbf{q}\rangle}{\langle\bar{\mathbf{o}},\mathbf{o}\rangle}$作为〈**o**，**q<sp_3〉〉的估计量。即便我们在计算〈¯o，q<sp_6〉〉时获得完全精确的结果，对〈o，q<sp_9〉〉的估计仍为近似值。因此，我们并非精确计算〈¯o，q<sp_12〉〉，而是旨在确保计算〈¯o**，q</sp_15〉〉时产生的误差远小于该估计量本身的误差。

具体而言，我们对**q**的每个分量应用均匀标量量化，并将它们表示为B_q位无符号整数。我们将向量**q**的*第 i 个*分量记作 q，[i]。令v_l := $\min_{1\leq i\leq D}$**q**，[i]，ur:=$\max_{1\leq i\leq D}$**q**，[i]，且 Δ := (v_r_ul)/(2 ^{B_q} −1)。该均匀标量量化方法将值域 [ul，ur] 均匀划分为 2 ^{B_q}_1 个区间，每个区间的长度为 Δ。对于任意值u=v_l+m· Δ +t，*其中 m*= 0,1，…，2 ^{B_q}_1，且t ∈ [0，Δ)，本方法通过将其向上舍入至最近的区间边界进行量化（即：，v_l+m· Δ 或ul+(m+ 1) · Δ)，并用对应的*Bq*-位无符号整数（即m或m+ 1）表示。令¯**q**为各分量等于**q**各分量量化值后的向量（我们称其为量化查询向量），¯**qu**为其B_q-位无符号整数表示，其中¯**q**= Δ ·¯**qu**+v_l · **1**$_D$（注：**1**$_D$表示所有分量均为1的*D*维向量）。由此，我们可以将〈¯**x**，¯**q**〉计算为〈¯**x**，**q**〉的近似值。

此外，为保持理论保证，我们采用了对均匀标量量化[3, 93]进行随机化的技巧。具体而言，与传统方法中将数值向上舍入至分段最近边界不同，随机化方法则将其随机舍入至左侧或右侧边界。其原理是：对于数值u=v_l+m·Δ+t，m= 0,1，…，2 ^{B_q}_1，t ∈ [0，Δ)，当该值被舍入至 u $_l$+m· Δ 时，会导致低估误差 _t <0；当被舍入至v_l+ (m+ 1) · Δ 时，则会导致高估误差 Δ _t >0。若以 1 _t/Δ 的概率赋予前一种情况，以t/Δ 的概率赋予后一种情况，则期望误差将为 0，从而使计算结果无偏。需注意的是，此操作可通过以下方式轻松实现：

$$\bar{\mathbf{q}}_u[i]:=\left\lfloor\frac{\mathbf{q}'[i]-v_l}{\Delta}+u_i\right\rfloor \quad (18)$$

其中ui从[0, 1]上的均匀分布中采样获得。此外，基于随机化方法，我们可以分析为使均匀标量量化引入的误差可忽略而所需的最小B_q值。相关结果由以下定理给出。详细证明可参阅技术报告[33]。

定理 3.3.B_q=Θ(log log *D*) *足以以高概率保证*| 〈$\bar{\mathbf{x}}$，**q**，〉 _ 〈$\bar{\mathbf{x}}$，$\bar{\mathbf{q}}$〉 | = *O*(1/$\sqrt{D}$)。

回顾可知，该估计量的误差为*O*(1/$\sqrt{D}$)（参见第3.2.2节）。上述定理表明，设定*Bq*= Θ(log log *D*) 即可确保均匀标量量化引入的误差与估计器引入的误差处于同一量级。由于该误差随*Bq*呈指数级衰减，因此将B_q增加一个微小常数（即B_q仍保持在 Θ(log log *D*) 量级），即可保证量化误差远小于估计器误差。我们在第5.2.5节中提供了关于B_q的实证验证研究，结果表明当B_q= 4 时，均匀标量量化引入的误差可忽略不计。

3.3.2 高效计算 〈$\bar{\mathbf{x}}$，$\bar{\mathbf{q}}$〉。接下来，我们将介绍如何高效计算 〈$\bar{\mathbf{x}}$，$\bar{\mathbf{q}}$〉。我们首先将 〈$\bar{\mathbf{x}}$，$\bar{\mathbf{q}}$〉 用$\bar{\mathbf{x}}$**b**，$\bar{\mathbf{q}}$**u**表示如下。

$$\langle \bar{\mathbf{x}}, \bar{\mathbf{q}} \rangle = \left\langle \frac{2\bar{\mathbf{x}}_b - \mathbf{1}_D}{\sqrt{D}}, \Delta \cdot \bar{\mathbf{q}}_u + v_l \cdot \mathbf{1}_D \right\rangle \tag{19}$$

$$= \frac{2\Delta}{\sqrt{D}} \langle \bar{\mathbf{x}}_b, \bar{\mathbf{q}}_u \rangle + \frac{2v_l}{\sqrt{D}} \sum_{i=1}^{D} \bar{\mathbf{x}}_b[i] - \frac{\Delta}{\sqrt{D}} \sum_{i=1}^{D} \bar{\mathbf{q}}_u[i] - \sqrt{D} \cdot v_l \tag{20}$$

需要注意的是，当我们对查询向量进行量化时，因子 Δ 与v_l均为已知。$\sum_{i=}^{D}1$ $\bar{\mathbf{x}}$**b**[*i*] 表示位串$\bar{\mathbf{x}}$**b**中 1 的个数，该值可在索引阶段预先计算得出。$\Sigma_{i=}^{D}1$ $\bar{\mathbf{q}}$**u**[*i*] 仅依赖于查询向量，其计算成本可由所有数据向量共享。剩余任务是计算 〈$\bar{\mathbf{x}}$**b**，$\bar{\mathbf{q}}$**u**〉，其中$\bar{\mathbf{x}}$**b**的坐标为 0 或 1，而$\bar{\mathbf{q}}$**u**的坐标为无符号B_q位整数。

我们为〈$\bar{\mathbf{x}}$**b**，$\bar{\mathbf{q}}$**u**〉提供了两种快速计算方案。第一种方案针对*单个*量化码场景，这与PQ[45]的原始实现方式一致；第二种方案针对打包后的*批量*量化码场景，这与PQ[4, 5]的快速SIMD实现方式一致。需要说明的是，在第二种场景下，我们的方法与PQ算法通常均比第一种场景具有更高的吞吐量——即在相同时间内可估算更多量化码的距离。但第二种场景要求量化码需以批量形式打包，这仅在特定应用场景下可行。

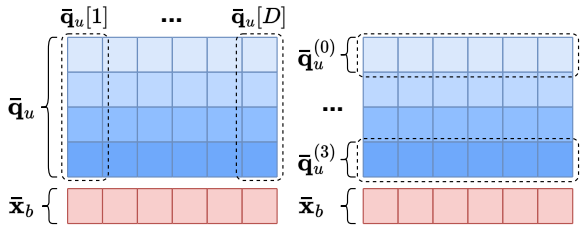


图 2：$\bar{\mathbf{q}}$u 的位分解。

对于首个将距离估计应用于查询向量与*单个*量化码的情形，我们注意到：一个无符号B_q-位整数可分解为B_q个二进制值，如图2所示。左图展示了〈$\bar{\mathbf{x}}$**b**，$\bar{\mathbf{q}}$**u**〉的朴素计算方式；右图则展示了本文提出的〈$\bar{\mathbf{x}}$**b**，$\bar{\mathbf{q}}$**u**〉的按位计算方式。令$\bar{\mathbf{q}}$**u**$^{(j)}$[*i*]∈{0,1}表示$\bar{\mathbf{q}}$**u**[*i*]的*第j位*，其中0≤ *j*<B_q。以下表达式阐明了该方法的原理。

$$\langle \bar{\mathbf{x}}_b, \bar{\mathbf{q}}_u \rangle = \sum_{i=1}^{D} \bar{\mathbf{x}}_b[i] \cdot \bar{\mathbf{q}}_u[i] = \sum_{i=1}^{D} \bar{\mathbf{x}}_b[i] \cdot \sum_{j=0}^{B_q-1} \bar{\mathbf{q}}_u^{(j)}[i] \cdot 2^j \tag{21}$$

$$= \sum_{j=0}^{B_q-1} 2^j \cdot \sum_{i=1}^{D} \bar{\mathbf{x}}_b[i] \cdot \bar{\mathbf{q}}_u^{(j)}[i] = \sum_{j=0}^{B_q-1} 2^j \cdot \left\langle \bar{\mathbf{x}}_b, \bar{\mathbf{q}}_u^{(j)} \right\rangle \tag{22}$$

公式（22）表明，〈$\bar{\mathbf{x}}$**b**，$\bar{\mathbf{q}}$**u**〉可表示为两个二进制向量内积的加权和，即对于 0 ≤ *j* <B_q，有 〈$\bar{\mathbf{x}}_b$，$\bar{\mathbf{q}}_u^{(j)}$〉。特别地，我们注意到，二进制向量的内积可通过位运算——即按位与运算与位计数运算（亦称 bitcount）——高效实现。因此，〈$\bar{\mathbf{o}}$，**q**〉的计算最终可简化为对*D*位字符串执行B_q次按位与运算与位计数运算，而此类操作已被几乎所有平台广泛支持。作为对比，如[4]中全面研究所示，PQ 方法依赖于在 RAM 中查找查找表（LUT），而此类操作无法高效实现。根据第5.2.1节的实验结果，在保持相同精度的前提下，本方法平均运行速度较 PQ 及 OPQ（PQ 的一种常用变体[34]）快 3 倍。

对于第二种情况——即针对查询向量与一打包的*批量*量化码进行距离估计时，我们注意到本方法可无缝采用与PQ相同的基于快速SIMD的实现方案[4, 5]。具体而言，对于一条*D*位字符串，我们将其划分为*D*/4个子段，每个子段包含4位。随后，我们对*D*/4个查找表进行预处理，每个查找表包含2 ^{4}个无符号整数，这些整数分别对应$\bar{\mathbf{q}}$**u**的子段与4位子段中2^{4}种可能二进制字符串的内积值。对于数据向量的量化码，我们可通过*D*/4次查询并累加查找表中的值，计算出〈$\bar{\mathbf{x}}$**b**，$\bar{\mathbf{q}}$**u**〉。需注意的是，该计算过程恰好转化为PQ算法的形式，因而可无缝采用基于快速SIMD的实现方案。需补充说明：本方法默认使用*D*位量化码，而PQ与 OPQ 默认使用2D位量化码。因此，在我们基于量化向量计算近似距离时，本方法相较于PQ和 OPQ 具有更高的效率。此外，如第5.2.1节所示，在默认设置下，尽管本方法使用的量化码较短（即*D*对比2D），其准确性仍持续优于PQ和 OPQ 。

3.4 RaBitQ 概述

我们将 RaBitQ 算法总结于算法1（索引阶段）与算法2（查询阶段）中。在索引阶段，算法以一组原始数据向量为输入，依据第3.1.1节（第1行）对向量集进行归一化处理，根据第3.1.2节（第2行）通过采样随机正交矩阵*P*构建 RaBitQ 码本，并依据第3.1.3节（第3行）计算量化码$\bar{\mathbf{x}}$**b**。在查询阶段，算法以原始查询向量、数据向量的标识符集合以及 RaBitQ 方法的预处理变量作为输入，首先对原始查询向量执行逆变换、归一化与量化操作（第1-2行）；需注意的是，上述步骤的时间开销可由所有数据向量共享。随后，针对每个输入的数据向量标识符，算法高效计算相应值。$\frac{\langle \bar{\mathbf{o}}, \mathbf{q} \rangle}{\langle \bar{\mathbf{o}}, \mathbf{o} \rangle}$ 基于第 3.3.2 节，将其作为基于第3.2节的 〈**o**，**q**〉 的无偏估计，并进一步基于第3.1.1节（第 3-5

行）计算原始查询向量与原始数据向量之间的估计距离。

算法 1： RaBitQ（索引阶段）

输入： 一组原始数据向量

输出： 采样矩阵P；量化码$\bar{\mathbf{x}}_b$；聂**或_c**聂及$\langle \bar{\mathbf{o}}, \mathbf{o} \rangle$的预计算结果

1 对向量集进行归一化处理（见第3.1.1节）

2 从随机正交矩阵P中抽取样本，以构建码本 Crand（见第3.1.2节）

3 计算量化码$\bar{\mathbf{x}}_b$（见第3.1.3节）

4 预先计算聂**或c**聂与$\langle \bar{\mathbf{o}}$

算法 2： RaBitQ（查询阶段）

Input : A raw query vector $\mathbf{q}_r$; the sampled matrix P; a set of IDs of the data vectors, their quantization codes $\bar{\mathbf{x}}_b$ and the results of $\|\mathbf{o}_r - \mathbf{c}\|$ and $\langle \bar{\mathbf{o}}, \mathbf{o} \rangle$

Output : A set of approximate distances between the raw query and the raw data vectors

1. 对原始查询向量进行归一化处理及逆变换, and obtain $\mathbf{q}$

2 Quantize $\mathbf{q}'$ into $\bar{\mathbf{q}}$ (Section 3.3.1)

3 **foreach** *input ID of the data vectors* **do**

4 Compute the value of the estimator $\frac{\langle \bar{\mathbf{o}}, \mathbf{q} \rangle}{\langle \bar{\mathbf{o}}, \mathbf{o} \rangle}$ as an approximation of $\langle \mathbf{o}, \mathbf{q} \rangle$ (Section 3.3.2)

5 Compute an estimated distance between the raw query and the data vector based on Equation (2)

4 RABITQ 用于内存中 ANN 搜索

接下来，我们展示将我们的方法应用于内存中的ANN搜索。值得注意的是，流行的量化方法PQx4fs已被与基于倒排索引的索引（如IVF[45]）或基于图的索引（如 NGT -QG[43]）结合使用，以实现内存中的ANN搜索。量化方法与IVF的结合可以轻松实现，无需过多努力。例如，我们可以使用量化方法来估计待探查簇中数据向量之间的距离，从而根据精确距离决定这些向量是否需要重新排序。在这种情况下，可以构建一批数据向量，并采用基于SIMD的快速实现方案（即PQx4fs）。然而，若将量化方法与基于图的方法（如 NGT -QG）结合使用，则需要付出更多努力，才能使这种组合方法在内存环境中具备竞争力，这本身也具有独立的研究价值。这是因为在基于图的方法中，待搜索的向量是在运行时根据贪心搜索过程逐一确定的，因此难以将其组织成批量处理，从而无法采用基于 SIMD 的快速实现方案。为此，本文中将本方法与 IVF 索引[45]相结合使用。将本量化方法应用于基于图的方法，则作为我们的后续研究方向。

我们如下展示基于 IVF 指数的 RaBitQ 方法的工作流程。在索引阶段中

，对于一组原始数据向量，该 IVF 算法首先采用 K-Means 算法对数据点进行聚类，为每个聚类构建一个“桶”，并将向量分配至对应桶中。随后，本方法基于各聚类对应的质心对原始数据向量进行归一化处理，并将这些归一化后的向量集合输入至 RaBitQ 方法的后续步骤中。在查询阶段，针对一个原始查询向量，算法会选取前N_{probe}聚类，其质心与查询向量的距离最近；接着，对于每个被选中的聚类，算法会检索所有量化码，并基于这些量化码估算其距离，进而根据精确距离对需重新排序的向量进行筛选。

关于重排序[85]，PQ及其变体方法设定一个固定超参数，该参数决定了需要重排序的数据向量数量（即对估计距离最小的向量进行重排序）。具体流程为：检索原始数据向量，计算精确距离，进而确定最终最近邻。值得注意的是，该超参数的调优基于经验，且往往较为困难——因为其在不同数据集间的取值差异可能极大（参见第5.2.3节）。相比之下，如第3.2节所述，本方法具有严格的误差界（需注意该误差界是严格数学保证的，且无论数据分布如何均成立）。因此，我们仅依据该误差界来确定需重排序的数据向量，而无需调优超参数。具体而言：若某数据向量的距离下界大于当前搜索最近邻的精确距离，则将其剔除；否则，计算其精确距离以进行重排序。基于这一理论误差界，重排序策略可确保以高概率将真实最近邻从已探查的簇中正确传递至重排序阶段。实证验证可参见第5.2.4节。我们需强调的是，基于界值的重排序思想并非首创。数据库研究领域已有诸多研究采用类似策略[24, 27, 76, 89, 90, 94]，以提升各类数据类型的相似性搜索鲁棒性。值得注意的是，除基于误差界的重排序思想外，RaBitQ还对界值的紧致性进行了严谨的理论分析，并如第3.2.2节所述，实现了渐近最优性。

此外，需要特别指出的是，重新排序是推进RaBitQ在人工神经网络（ANN）搜索鲁棒性距离方面建立严格误差界的关键步骤。具体而言，当ANN搜索对精度的要求高于RaBitQ所能保证的精度时（例如：查询向量与两个不同数据向量的真实距离极为接近），RaBitQ提供的距离估计值在正确排序这些向量时将效果欠佳。此时，重新排序对于实现高召回率至关重要。值得注意的是，当距离值极度接近时，任何距离估计方法本身均面临固有困难。

5 实验

5.1 实验装置

我们的实验包含三个部分。首先，我们在距离估计的时间精度权衡与索引相位的时间成本方面，将本方法与传统量化方法进行比较（结果详见第5.2.1节与第5.2.2节）。其次，我们将这些方法应用于内存ANN场景进行对比（结果详见第5.2.3节）。对于ANN任务，我们遵循[30]的方法，针对每个查询检索100

个最近邻，即K=100。第三，我们通过实验验证理论分析的正确性（结果详见第5.2.4至5.2.6节）。最后，需要指出的是：RaBitQ是一种具备严格理论保证的方法，其各组件构成一个有机整体，共同确保了其渐近最优性能；若移除任一组件，不仅会导致理论保证失效（即该方法退化为启发式策略，性能亦无法再从理论上预测），还会使基于误差界的重排序机制失效（详见第4节）。尽管如此，我们仍已在技术报告[33]中纳入实证消融研究。**数据集**：我们采用了六个规模与维度各异的公开真实世界数据集，其详细信息可参见表3。这些数据集已被广泛用于人工神经网络算法的基准测试[6,58, 62, 67]。特别值得注意的是，已有研究报道，在 SIFT、DEEP 及 GIST 数据集上，PQx4fs 与 OPQx4fs 均展现出良好的实证性能[5]。需特别说明的是，上述所有公开数据集均同时提供数据向量与查询向量。

表 3：数据集统计量

数据集	尺寸	D	查询大小	数据类型
Msong	992,272	420	200	音频
筛分	1,000,000	128	10,000	图像
深的	1,000,000	256	1,000	图像
Word2Vec	1,000,000	300	1,000	文本
胃肠道间质瘤	1,000,000	960	1,000	图像
图像	2,340,373	150	200	图像

算法。首先，为估计数据向量与查询向量之间的距离，我们考虑了三种基准方法：PQ[45]、 OPQ[34]以及 LSQ[66, 67]。特别地，（**1）PQ**与（**2）OPQ**是量化方法中最为流行的两种方法[34, 45]，已在工业领域广泛部署[48, 69, 84, 92]。PQ 与 OPQ 的普及表明，这两种方法已得到最广泛的实证评估，且预期具备已知最优的稳定性。因此，我们将 PQ 与 OPQ 作为主要基准方法，代表尚无理论误差界量的量化方法。另一类量化方法称为加法量化[8, 66, 67, 95]，与 PQ 相比，这类方法追求极致精度，但代价是在索引阶段优化码本及将数据向量映射至量化码所需时间大幅增加。（**3）LSQ**[66, 67]则是该类别中的前沿方法。因此，我们采用 LSQ 作为基准方法，代表在查询阶段追求极致性能的量化方法。这些基准方法均取自开源库 Faiss[48]的 1.7.4 发行版，该版本已充分利用 AVX2 的 SIMD 指令进行了优化。其次，对于 ANN，我们根据第5.2.1节的结果，将我们的方法与最具竞争力的基准方法 OPQ 进行比较。对于我们的方法和 OPQ，我们都按照第4节的规定，将其与 IVF 索引结合使用。我们还加入了与**HNSW**[65]的比较作为参考。后者是图基方法中的前沿技术之一，已在[6, 86]中进行了基准测试，并且在工业领域也被广泛采用[48, 69, 84, 92]。其实现代码取自 hnswlib[65]，并已利用 AVX2 的 SIMD 指令进行了优化。我们注意到，最近提出的量化方法 ScaNN[37]为构建 PQ 的量化码本提出了一个新的目标函数，并声称其实证性能更优。然而，正如文献[6]中所报道，其卓越性能主要归功于基于SIMD的快速实现[5]。当使用相同技术实现PQ时，这一优势便不复存在。因此，我们将其排除在比较之外。此外，我们也排除了与 LSH 方法的比较，因为已有研究指出，在达到相同召回率时，量化方法在效率上比这些方法高出数个数量级[58]。LSH 领域的最新进展并未改变这一趋势[80]。因此，与量化方法相当的性能表明，相较于 LSH 方法已有显著改进。

性能指标。首先，为估计数据向量与查询向量之间的距离，我们采用两个指标来衡量准确性，以及一个指标来衡量效率。具体而言，我们通过以下两种方式评估准确性：(1) 平均相对误差；(2) 估计平方距离的最大相对误差。前者用于衡量估计距离的整体质量，而后者则用于衡量估计距离的鲁棒性。效率则通过每个向量进行距离估计所需的时间来衡量。需要注意的是，由于缓存效应的影响，效率会随向量距离估计的顺序而改变。为模拟实际应用中各方法的执行顺序，我们对所有方法构建 IVF 索引，并按照 IVF 索引遍历聚类时的顺序进行距离估计。随后，我们计算数据集中所有量化码进行距离估计的端到端总时间，并将其除以数据集规模。此外，我们还将查询阶段的预处理时间（例如本方法中对查询向量进行归一化、转换及量化所需的时间）纳入考量，以确保对比结果的公平性。我们还在索引阶段测量了这些方法的时间成本。其次，对于人工神经网络（ANN），我们采用召回率和平均距离比来衡量ANN搜索的准确性。具体而言，召回率是指检索到的真实最近邻数量与K的比值；平均距离比则是所返回的K个数据向量与真实最近邻之间距离比的平均值。这些指标被广泛用于评估ANN算法的准确性[6, 31, 38, 58,78]。我们采用每秒查询数（QPS），即一种方法在一秒内可处理的查询数量，来衡量其效率。这一指标也被广泛用于评估ANN算法的效率[6, 58, 86]。遵循[6, 58, 86]的方法，查询时间是在单线程环境下评估的，且每次查询均单独进行搜索（而非批量处理）。所有指标均在每个单独查询上测量，然后对整个查询集取平均值。

参数设置。如 Faiss[25]所建议，由于数据集规模达百万量级，IVF 的聚类数设定为 4,096。本方法包含两个参数：ϵ_0与B_q。第3.2.2节及第3.3.1节的理论分析已明确给出：$\epsilon_0 = \Theta(\sqrt{\log(1/\delta)})$且$B_q = \Theta(\log\log D)$，其中$\delta$表示失败概率。实际应用中，所有数据集的参数均固定为ϵ_0=1.9 与B_q=4。实证参数研究详见第5.2.4节与第5.2.5节。关于量化码长度，根据定义其值等于D，但也可在生成量化码前用零填充原始向量来调整该值[7]。根据定理3.2，填充的零数量越多，量化码长度越长，精度也越高

[6]https://github.com/facebookresearch/faiss/wiki/Indexing-1M-vectors

[7]我们强调，填充后的维度在生成阶段后将不再保留，因此不会影响与原始向量相关的时空成本。

（需注意误差上界为$O(1/\sqrt{D})$）。默认情况下，量化码的长度被设置为不小于D的最小 64 的倍数（等于或略大于D），以便能够存储由一系列 64 位无符号整数组成的比特串。对于传统量化方法（包括 PQ、 OPQ 和 LSQ），有两个参数，即量化码的子段数量M和重新排序候选数量，这两个参数均需通过经验调整来确定。遵循默认参数设置[25, 37]，我们将分区数设为$M=D/2$。需要注意的是，对于 PQ 和 OPQ 方法，由于D必须能被M整除，因此该值无法进一步增加。重新排序候选数量则在 500、1,000 和 2,500 之间变化。第5.2.3节中的实验结果表明，这些参数中没有一个在不同数据集上均能持续表现出良好性能。对于 HNSW，我们遵循其原始论文[65]，将图中每个顶点的最大出度设为 32（对应*MH NSW*= 16），并将控制图构建过程的参数*ef construction*设为 500。

C++ 源代码使用 g++ 9.4.0 编译器并配合 -Ofast 选项进行编译。-实验环境为 Ubuntu 20.04LTS 上的 march=core-avx2 架构；Python 源代码在 Python 3.8 上运行。所有实验均在配备 AMD Threadripper PRO 3955WX 3.9GHz 处理器（采用 Zen2 微架构，支持直至 AVX2 的 SIMD 指令）及 64GB 内存的机器上完成。代码与数据集均可在https://github.com/gaoj0017/RaBitQ获取。

5.2 实验结果

*5.2.1 用于距离估计的每个向量的时间-精度权衡。*我们采用包括 PQ、 OPQ 、 LSQ 及本文提出的 RaBitQ 在内的多种量化方法，分别估算数据向量（来自数据向量集合）与查询向量（来自查询向量集合）之间的距离。通过改变量化码的长度，我们在图3中绘制了“平均相对误差—每个向量的时间”曲线（左图，左下角效果更佳）以及“最大相对误差—每个向量的时间”曲线（右图，左下角效果更佳）。特别地，对于本文提出的方法，绘制曲线时，我们在生成量化码时通过在向量中填充不同数量的 0 来改变码长；而对于 PQ、 OPQ 和 LSQ，则通过设置不同的M来改变码长（需注意：对于 PQ 和 OPQ，D必须能被M整除）。

根据图3中的结果，我们得出以下观察结果：(1) LSQ 的性能稳定性远低于 PQ 和 OPQ 。除数据集 SIFT 和 DEEP 外，LSQx4fs 的准确率均低于 PQx4fs 和 OPQx4fs。(2)对比实线曲线可以发现，在比特数默认设置下（该设置对应红色与橙色实线曲线的最后一个点，以及绿色实线曲线的第一个点），我们的方法在所有测试数据集上均持续展现出优于 PQ 和 OPQ 的准确率，同时保持相当的效率。需要强调的是，在默认设置下，本方法的量化码长度仅为 PQ 与 OPQ 的一半左右（即D对比 2D）。(3)对比虚线曲线可知，在达到相同准确率时，本方法的效率显著优于 PQ 与 OPQ 。(4)在数据集 Msong 上，PQx8 与 OPQx8 的准确率处于正常水平，而 PQx4fs 与 OPQx4fs 的准确率则严重下降。这表明，传统量化方法在k=8 时表现出的合理准确率，并不能保证其在使用k=4 时仍能保持正常性能。因此，使用基于快速SIMD的实现[5]来加速传统量化方法并不总是可行。另一方面，在其它数据集上，采用k=8的传统量化方法的效率几乎无法与采用k=4的方法相媲美。这表明，PQ在内存ANN中的近期成功，很大程度上归功于基于快速SIMD的实现。因此，为了追求稳定性而用原始实现替代基于快速SIMD的实现，并非可行之选。(5)除SIFT和DEEP数据集外，PQx4fs与OPQx4fs的最大相对误差均约为100%。这表明，即使在PQ和 OPQ 通常表现良好的数据集上，它们也无法稳健地生成高精度估计距离。相比之下，我们的方法在所有测试数据集上的最大相对误差均不超过40%。

表 4：GIST 数据集的索引时间

	RaBitQ	PQ	OPQ	LSQ
时间	117s	105s	291s	暂停期（>24 小时）

*5.2.2 索引阶段耗时。*在表4中，我们报告了在默认参数设置下，使用 CPU 上 32 个线程时，PQ、 OPQ 和 LSQ 等量化方法的索引耗时（其中 PQ、 OPQ 和 LSQ 的k= 4）。结果表明，对于我们的方法、PQ 和 OPQ，索引耗时并非瓶颈，因为它们均能在几分钟内完成索引阶段。然而，对于 LSQ，则需超过 24 小时。这是因为在 LSQ 中，将数据向量映射至其量化码的步骤是 NP-难的[66, 67]。尽管已提出若干近似解决这一 NP-难问题的技术[66, 67]，但其时间成本仍远大于 PQ，这极大限制了其在实际应用中的使用。

*5.2.3 ANN搜索中的时间-精度权衡。*随后，我们评估了这些算法在与IVF索引结合用于ANN搜索时的性能。根据第5.2.1节的结果，我们仅选取OPQx4fs-batch和RaBitQ-batch进行对比，因为当允许量化码以批处理方式打包时，其他方法或实现通常处于劣势。作为参考，我们还纳入了 HNSW 进行对比。接着，我们通过改变在IVF索引中探查的桶数，绘制了“QPS”-“召回率”曲线（左图，右上为更优）以及“QPS”-“平均距离比”曲线（右图，左上方为更优），如图4所示。对于 HNSW，我们通过调整一个名为*ef search*的参数来绘制其曲线，该参数控制 HNSW 的 QPS -召回率权衡。对于 OPQ，我们展示了三条曲线，分别对应三种不同的重排序候选数量。基于图4，我们得出以下结论：(1)在所有测试数据集上，无论重排序参数如何，我们的方法均持续优于 OPQ 。我们强调，已有报道指出，在 SIFT、DEEP 和 GIST 数据集上，OPQx4fs 具有良好的实证性能[5]。我们的方法在所有测试数据集上也持续优于 HNSW 。(2)在 MSong 数据集上，即使应用重新排序， OPQ 的性能仍极为糟糕。特别是，随着 IVF 索引探查的桶数增加，OPQ 的召回率异常下降，这是因为 OPQ 在估计距离时引入了过多误差。图3中显示的低准确率可以解释这一糟糕表现。

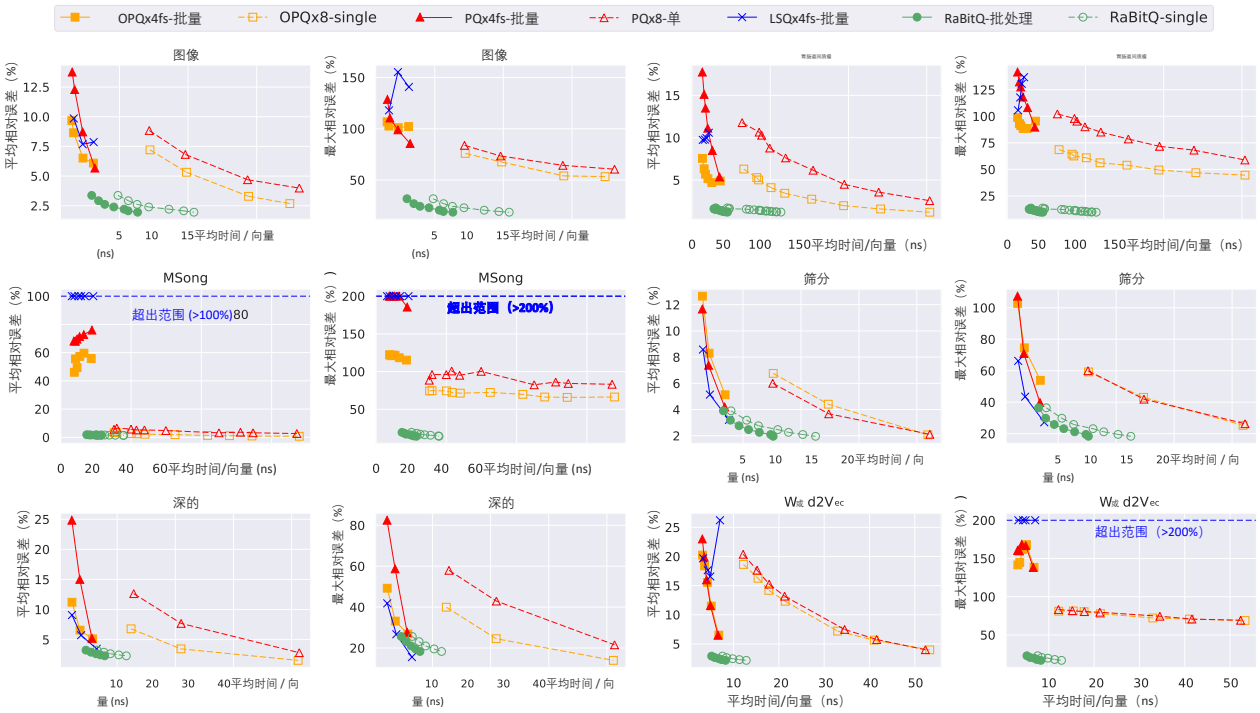


图 3：距离近似中的时间-精度权衡。对于基准方法，(1) "x4fs-batch" 表示采用基于 SIMD 的快速实现方案（其中 4 位比特用于编码量化码，且每次计算 32 个数据向量的近似距离）；(2) "x8-single" 表示使用 8 位比特编码量化码，且每次仅计算单个数据向量的近似距离。此外，LSQx8-single 的结果被省略，因为该方案结合 Faiss 的实现时，其时间开销显著高于其他方法。

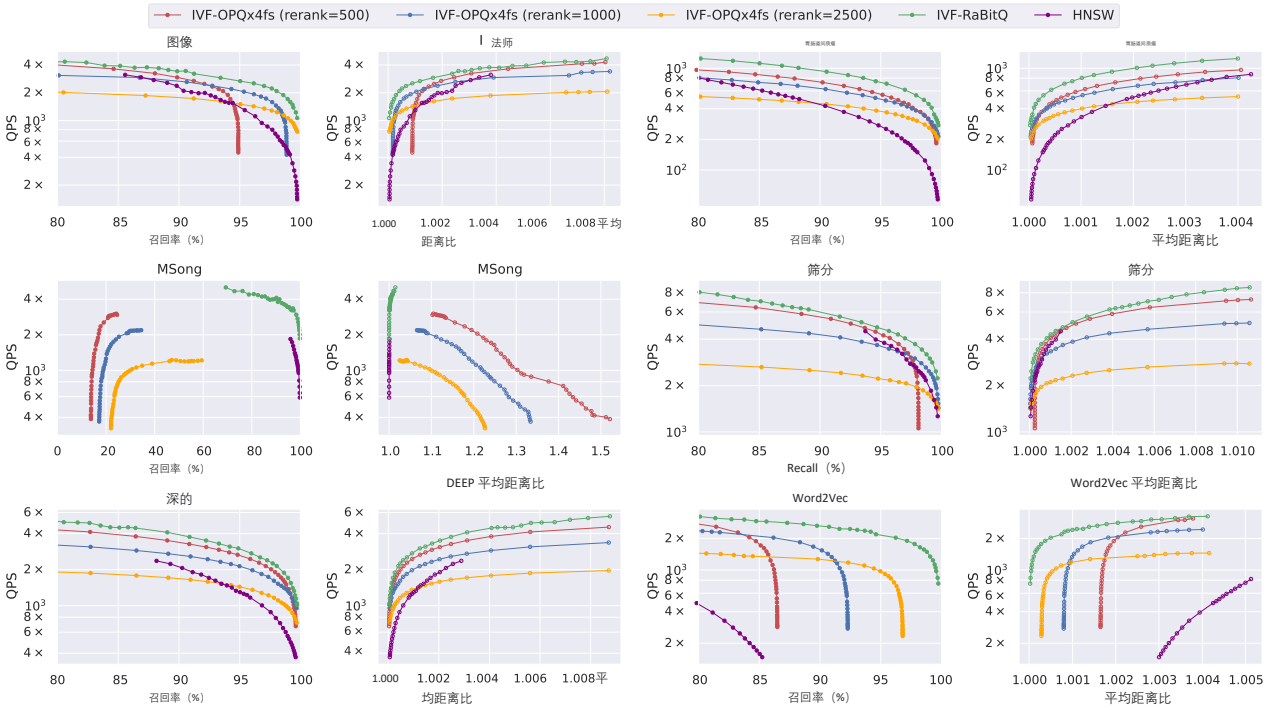


图 4：ANN 搜索中的时间-准确率权衡。参数*rerank*表示重新排序的候选样本数量。

失败。(3)对于 OPQ，没有一个单一的重排序参数能在所有数据集上都表现良好。在 SIFT、DEEP 和 GIST 上，仅需 1,000 个重排序候选样本即可获得近乎完美的召回率；而在 Image 和 Word2Vec 上，则需要更多重排序候选样本。我们注意到，重排序参数的调优往往需要 exhaustive 尝试，因为这些参数与数据集及其他参数等多种因素相互交织。在测试之前，实际上并无可靠方法可预测参数的最优设置。相比之下，如第3.2.2节和第3.3.1节所述，本方法中的理论分析可为参数提供明确建议。因此，本方法无需调参。

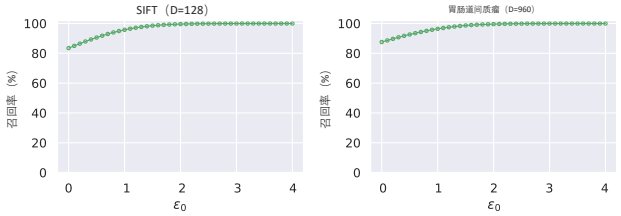


图 5：ϵ_0的验证研究。

5.2.4 关于下述命题的验证结果 ϵ_0. ϵ_0是一个控制误差界置信区间的参数（参见第3.2.2节）。当在ANN搜索中应用RaBitQ方法时，该参数还会进一步控制我们将NN正确送入重排序阶段的概率（参见第4节）。特别地，为确保失败概率不超过δ，第3.2.2节中的理论分析建议将ϵ_0设为 $\Theta(\sqrt{\log(1/\delta)})$。我们强调，该命题与数据集或其他参数设置等任何其他因素无关，因此该参数无需调优。在图5中，我们针对该命题提供了实证验证：通过将ϵ_0从0.0逐步调整至4.0，绘制出“召回率”–“ϵ_0”曲线。召回率是通过估算*所有*数据向量的距离，并根据第4节中的策略决定需要重新排序的向量来衡量的（需注意：若真正的最近邻未被重新排序，则会被遗漏）。由此，可能影响召回率的因素（量化方法的误差除外）均被消除。图5显示，在两个不同数据集上，两条曲线均呈现出高度相似的趋势：在$\epsilon_0 \approx 1.9$ 附近均可达到近乎完美的召回率。

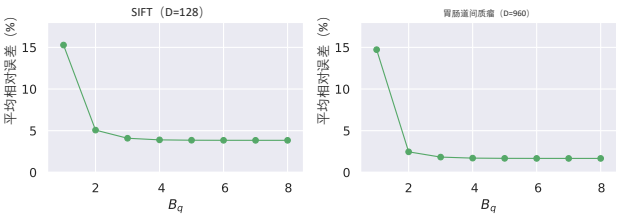


图 6：B_q的验证研究。

5.2.5 验证关于 Bq 的声明about B_q. B_q是一个用于控制计算过程中引入误差的参数〈**o**，**q**〉。根据第 3.3.1 节中的分析，*Bq*= Θ (log log *D*) 足以确保在计算〈$\bar{\mathbf{o}}$**q**的误差远小于估计量的误差。我们注意到 Θ(log log *D*) 关于*D*的变化极其缓慢，因此当维度未发生显著变化时，可将其视为常数。在图6中，我们针对该结论提供了实证验证。具体而言，我们通过将B_q从 1 递增至 8，绘制了“平均相对误差”–“B_q”曲线。图6表明，在两个不同数据集上，两条曲线均呈现出高度相似的趋势：误差在B_q= 4 附近快速收敛。另一方面，我们还需强调：若进一步减小B_q，则会在〈的计算中引入不可忽略的误差。$\bar{\mathbf{o}}$，**q**〉。特别地，当B_q= 1 时——即查询向量与数据向量均被量化为二进制字符串——其误差远大于B_q= 4 时的误差。这一结果或可解释为何二进制哈希方法难以取得良好的实证性能。

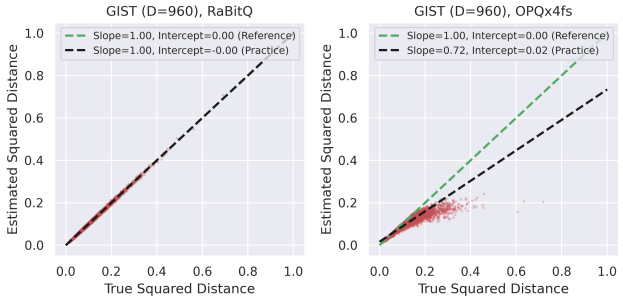


图 7：无偏性验证研究。

*5.2.6 无偏性验证结果。*在图7中，我们验证了本方法的无偏性，并展示了 OPQ 方法的偏倚性。为了验证无偏性，我们收集了107对查询向量与数据向量之间的估计平方距离和真实平方距离（即查询集中前10个查询向量与GIST完整数据集中106个数据向量）。这些距离值均通过最大真实平方距离进行归一化处理。我们使用线性回归对这107对数据点进行拟合，并将结果用黑色虚线绘制。需要注意的是，若某方法具有无偏性，则其线性回归结果应具有斜率为1且y轴截距为0的特性（以绿色虚线作为参考）。图7清晰表明，本方法确实具有无偏性，这验证了第3.2.2节中的理论分析。另一方面， OPQ 方法生成的估计距离则明显存在偏倚。

6 相关工作

近似最近邻搜索。现有关于ANN搜索的研究通常可分为四类：(1) 基于图的方法[29, 30, 58, 64, 65, 74]；(2) 基于量化方法的方法 [8,34, 36, 37, 45, 66, 67, 73, 95]；(3) 基于树结构的方法 [10, 15, 17, 71]；以及 (4) 基于哈希的方法 [18, 31, 35, 38, 39, 54, 56, 63, 78–80, 97]。如需全面综述，可参阅近期相关教程[23, 75]及基准测试/综述文献[6, 7, 19, 58, 86, 88]。值得注意的是，近年来许多研究通过联合考量不同类型

方法来设计算法或系统，从而使单一方法兼具两类方法的优势[1, 12, 13, 21, 43, 62, 96]。本文提出的量化方法既能提供精确的误差界，又兼具优异的实证性能；与传统量化方法类似，它可作为集成算法或系统的组成部分使用。本方法还具有两大优势：(1) 无需参数调优；(2) 可为单个量化码支持高效距离估计。这些优势可进一步促进其与其他类型方法的融合应用。近年来，已有诸多研究将机器学习（ML）应用于人工神经网络（ANN）[9, 20, 26, 55, 57, 87, 91]。

量化。关于高维向量量化，来自机器学习、计算机视觉和数据管理等不同领域的文献浩如烟海[8, 27, 34, 36, 45, 66, 67, 73, 81, 90, 95]。我们建议读者参阅综合性综述[24, 68, 83, 85]及参考书籍[76, 94]。值得一提的是，在[81]中，曾提及一种称为 Split- VQ 的量化方法。该方法涵盖了 PQ 的核心思想，即将向量划分为若干子段，为每个子段构建子码本，最后通过笛卡尔积构建完整码本。除 PQ 及其变体外，还存在其他类型的量化方法，例如标量量化[1, 27, 90]。这些方法分别对每个维度的标量值进行量化，通常采用比 PQ 更温和的压缩率，以换取更高的精度。特别是标量量化方法 VA+ File[27]，根据最新基准测试[24]，在数据序列的相似性搜索任务中已展现出领先的性能。除了对量化算法的研究外，我们还注意到，硬件感知优化（如 SIMD、GPU、 FPGA 等）对这些方法的性能也做出了重要贡献[4, 5, 47, 48, 61]。为了继承已充分发展的硬件感知优化的优势，在本研究中，我们将计算简化为 PQ 的计算（见第3.3节）。然而，RaBitQ 本质上可以通过更简单的位运算来实现（而 PQ 及其变体则无法做到这一点）。专用硬件感知优化能否进一步提升 RaBitQ 的性能，仍是一个值得探讨的问题。

高维向量理论研究。高维向量理论研究的核心在于奠基性成果——Johnson-Lindenstrauss (JL) 引理[49]。该引理表明：将向量的维度降至$O(\varepsilon^{-2}\log(1/\delta))$，即可保证误差界不超过$\varepsilon$。近年来的研究已在不同方面对JL引理进行了改进，例如：[53] 证明了 JLLemma 的最优性。[2,50] 我们提出用于降维的快速算法。读者可参阅一篇综合性综述[28]。本方法归属于近期一系列研究[3, 40, 41, 72]的范畴，这些研究旨在通过将高维向量压缩为短码来改进JL引理。作为对比，为确保误差界ε，JL引理需要$O(\varepsilon^{-2}\log(1/\delta))$*维* 的向量，而上述研究已证明，仅需$O(\varepsilon^{-2}\log(1/\delta))$*比特* 的短码即可。在实际应用中，我们注意到尽管现有研究在理论层面实现了空间复杂度（即保证特定误差界所需的最小比特数）的提升，但它们对效率提升的关注相对不足。特别是，这些方法并不适用于内存中的 ANN 搜索，因为在查询阶段估算距离时，它们需要解压短码，并使用解压后的向量计算距离，这会导致计算效率退化为暴力搜索。因此，这些方法在实际应用中并未被采用。相比之下，我们的方法如第3.3节所述，可实现实际高效的计算。

符号随机投影。我们注意到，有一系列研究被称为符号随机投影（SRP），这些研究通过在随机化后对向量进行二值化处理，生成一个短编码来估计向量间的角度值[11, 22, 46, 51]。我们的方法与这些研究在以下方面有所不同：(1)在问题层面，SRP 旨在无偏地估计角度值，而RaBitQ则旨在无偏地估计内积（进而估计平方距离）。需要注意的是，角度值与内积之间的关系是非线性的，因此针对其中一个问题的无偏估计量并不能直接推导出针对另一个问题的无偏估计量。(2)在理论层面，RaBitQ 提供的保证比 SRP 更强。具体而言，RaBitQ 保证每个数据向量的距离以高概率落在指定范围内；相比之下， SRP 仅对方差（即“平均”平方误差）给出界，且无法为每个估计值提供界。因此， SRP 无法支持相似性搜索中的重新排序。(3)在技术层面， SRP 中将位串视为某种哈希码，而 RaBitQ 中将位串视为二值向量的二进制表示。此外， SRP 将数据向量和查询向量均映射为位串，这从两个方面引入了误差。相比之下，RaBitQ 将数据向量量化为位串，而将查询向量量化为 4 位无符号整数向量。定理3.3证明，仅对查询向量进行量化只会引入可忽略不计的误差。因此，RaBitQ 仅从数据向量的角度引入误差。

7 结论

综上所述，我们提出了一种新型随机量化方法 RaBitQ，该方法在实证精度与严格理论误差界两方面均较 PQ 及其变体具有显著优势。基于简单位运算或快速 SIMD 运算的高效实现方案，进一步使其在内存内人工神经网络搜索的时间-精度权衡方面脱颖而出。在真实世界数据集上开展的广泛实验验证了以下两点：(1) 本方法在时间-精度权衡方面具有实证优势；(2) 实证性能与理论分析结果高度吻合。一些值得探索的研究方向包括：将本方法应用于人工神经网络搜索的其他场景（例如结合图索引或部署于其他存储设备[14, 42, 44, 59]）。此外，RaBitQ 还可便捷地用于无偏估计余弦相似度与内积[8]，这进一步彰显了其在最大内积搜索及神经网络量化领域的应用潜力。

致谢

我们谨对匿名评审专家提供的建设性反馈与宝贵建议表示感谢。本研究获新加坡教育部学术研究基金资助（Tier 2 Award

[8]两个向量的余弦相似度恰好等于它们单位向量的内积。**o**与**q**的内积可表示为 $\langle \mathbf{o}, \mathbf{q}\rangle = \langle \mathbf{o_c}+\mathbf{c}, \mathbf{q_c}+\mathbf{c}\rangle = \langle \mathbf{o_c}, \langle \mathbf{q_c}\rangle \rangle \cdot \langle (\mathbf{o_c})/\langle \mathbf{o_c}\rangle, (\mathbf{q_c})/\langle \mathbf{q_c}\rangle \rangle + \langle \mathbf{o}, \mathbf{c}\rangle + \langle \mathbf{q}, \mathbf{c}\rangle \cdot \langle \mathbf{c}\rangle^2$，其中**c**为数据向量的质心，该式可简化为对单位向量间内积的估计——如第3.1.1节所述。

MOE-T2EP20221-0013、Tier 2 Award MOE-T2EP20220-0011 及 Tier 1 Award (RG77/21)）。本文件中所载观点、研究结果、结论或建议均仅代表作者个人立场，不代表新加坡教育部的官方意见。

参考文献

[1] Cecilia Aguerrebere 、 Ishwar Singh Bhati、 Mark Hildebrand 、 Mariano Tepper 及 Theodore Willke 。2023。利用压缩索引实现瞬态相似性搜索。*《 VLDB Endow. 会议论文集》*第 16 卷，第 11 页（2023 年 8 月），第 3433–3446 页。https://doi.org/10.14778/3611479.3611537

[2] Nir Ailon 与 Bernard Chazelle。2009。快速 Johnson–Lindenstrauss 变换与近似最近邻算法。*SIAM J. Comput.*39,1 (2009)，302–322。https://doi.org/10.1137/060673096 arXiv:https://doi.org/10.1137/060673096

[3] Noga Alon 与 Bo 'az Klartag。2017。近似内积的最优压缩与维度降维。载于*2017年第58届IEEE计算机科学基础年度研讨会（FOCS）*，第639–650页。https://doi.org/10.1109/ FOCS .2017.65

[4] Fabien Andre 、Anne- Marie Kermarrec 与 Nicolas Le Scouarnec。2015。缓存位置不足：基于乘积量化快速扫描的高性能最近邻搜索。*《 VLDB Endow. 会议论文集》*第 9 卷第 4 期（2015 年 12 月），第 288–299 页。https://doi.org/10.14778/2856318.2856324

[5] Fabien Andre 、Anne- Marie Kermarrec 与 Nicolas Le Scouarnec。2017。基于快速 ADC 的加速最近邻搜索。载于*《2017年 ACM 国际多媒体检索会议论文集》*（罗马尼亚布加勒斯特）（*ICMR '17*）。美国纽约州纽约市，计算机器协会，第 159–166 页。https://doi.org/10.1145/3078971.3078992

[6] Martin Aumuller 、 Erik Bernhardsson 与 Alexander Faithfull 。2020。ANNBenchmarks：近似最近邻算法的基准测试工具。*Inf. Syst.*87，C（2020年1月），共13页。https://doi.org/10.1016/j.is.2019.02.006

[7] Martin Aumuller 与 Matteo Ceccarello。2023。《近似最近邻搜索的最新方法与趋势——兼论基准测试》。*数据工程*(2023)，89。

[8] Artem Babenko 与 Victor Lempitsky . 2014. 用于极端向量压缩的加性量化方法。载于*2014年IEEE计算机视觉与模式识别会议*，第931–938页。https://doi.org/10.1109/CVPR.2014.124

[9] Dmitry Baranchuk 、 Dmitry Persiyanov 、 Anton Sinitsin 与 Artem Babenko 。2019。在相似性图中学习路径规划。载于*《第36届国际机器学习会议论文集（《机器学习研究论文集》第97卷）》*，Kamalika Chaudhuri 与 Ruslan Salakhutdinov（编）。 PMLR，第475–484 页。https://proceedings.mlr.press/v97/baranchuk19a.html

[10] Alina Beygelzimer 、 Sham Kakade 与 John Langford 。2006。《最近邻算法中的覆盖树》。载于*《第23届国际机器学习会议论文集》*，第97–104页。

[11] Moses S.Charikar. 2002. 基于取整算法的相似性估计技术.载于*《第34届 ACM 计算理论年度研讨会论文集》*(加拿大魁北克省蒙特利尔)(*STOC '02*).美国纽约州纽约市:计算机协会,第 380–388 页.https://doi.org/10.1145/509907.509965

[12] Patrick H.Chen,Wei- Cheng Chang ,Jyun- Yu Jiang ,Hsiang- Fu Yu ,Inderjit S. Dhillon ,及 Cho- Jui Hsieh .2023.《finger:基于图的近似最近邻搜索的快速推理》.收录于*The Web Conference 2023*.https://www.amazon.science/publications/finger-fast-inference-for-graph基于图的近似最近邻搜索

[13] Qi Chen，Haidong Wang，Mingqin Li，Gang Ren，Scarlett Li，Jefery Zhu，Jason Li，Chuanjie Liu，Lintao Zhang，与 Jingdong Wang . 2018.*SPTAG：用于快速近似最近邻搜索的库* 。https://github.com/Microsoft/ SPTAG

[14] Qi Chen 、 Bing Zhao 、 Haidong Wang 、 Mingqin Li 、 Chuanjie Liu 、 Zengzhong Li 、 Mao Yang 及 Jingdong Wang 。2021。《高效百亿级近似最近邻搜索》。收录于*第35届神经信息处理系统会议（NeurIPS 2021）*。

[15] Paolo Ciaccia 、 Marco Patella 与 Pavel Zezula 。1997。《M-Tree：度量空间中相似性搜索的高效访问方法》。载于*《第23届超大规模数据库国际会议（VLDB '97）论文集》*。Morgan Kaufmann Publishers Inc.，美国加利福尼亚州旧金山，426–435页。

[16] T. Cover 与 P. Hart。1967。最近邻模式分类。*IEEE 信息论汇刊* 13,1 (1967)，21–27。https://doi.org/10.1109/TIT.1967.1053964

[17] Sanjoy Dasgupta 与 Yoav Freund . 2008. 随机投影树与低维流形。载于*《第40届 ACM 计算理论年度研讨会论文集》*，第 537–546 页。

[18] Mayur Datar 、 Nicole Immorlica 、 Piotr Indyk 及 Vahab S Mirrokni。2004。基于 p-稳定分布的局部敏感哈希方案。载于*《第二十届计算几何年度研讨会论文集》*，第 253–262 页。

[19] Magdalen Dobson 、 Zheqi Shen 、Guy E Blelloch、 Laxman Dhulipala 、 Yan Gu 、Harsha Vardhan Simhadri 及 Yihan Sun 。2023。将基于图的 ANNS 算法扩展到百亿级数据集：一项对比分析。*arXiv 预印本 arXiv:2305.04359*（2023）。

[20] Yihe Dong 、 Piotr Indyk 、 Ilya Razenshteyn 与 Tal Wagner 。2020。用于最近邻搜索的学习空间划分。载于*《国际学习表示会议》*。https://openreview.net/forum?id=rkenmREFDr

[21] Matthijs Douze 、 Alexandre Sablayrolles 与 Herve Jegou 。2018。链接与代码：基于图的快速索引及紧凑回归代码。载于*2018年 IEEE/ CVF 计算机视觉与模式识别会议*，第 3646–3654 页。https://doi.org/10.1109/CVPR.2018.00384

[22] Punit Pankaj Dubey，Bhisham Dev Verma，Rameshwar Pratap ，及 Keegan Kang . 2022. 通过计数草图改进符号随机投影。载于*《第38届人工智能不确定性会议论文集（机器学习研究论文集，第180卷）》*，James Cussens 与 Kun Zhang（编）。 PMLR，第599–609页。https://proceedings.mlr.press/v180/dubey22a.html

[23] Karima Echihabi 、 Kostas Zoumpatianos 与 Themis Palpanas 。2021。高维向量相似度搜索的新趋势：基于算法驱动、渐进式及分布式方法。*《 VLDB Endow. 会议论文集》*第 14 卷，第 12 页（2021 年 7 月），第 3198–3201 页。https://doi.org/10.14778/3476311.3476407

[24] Karima Echihabi 、 Kostas Zoumpatianos 、 Themis Palpanas 与 Houda Benbrahim 。2018。《数据序列相似性搜索中的 Lernaean Hydra：现有技术的实验评估》。*《 VLDB Endow. 会议论文集》*第 12 卷，第 2 页（2018 年 10 月），第 112–127 页。https://doi.org/10.14778/3282495.3282498

[25] Faiss。2023。Faiss。https://github.com/facebookresearch/faiss。

[26] Chao Feng 、 Defu Lian 、 Xiting Wang 、 Zheng Liu 、 Xing Xie 及 Enhong Chen 。2022。基于邻近图的强化路由以实现高效推荐。*ACM Trans. Inf. Syst.*（2022年1月）。https://doi.org/10.1145/3512767刚被接受。

[27] Hakan Ferhatosmanoglu 、 Ertem Tuncel 、 Divyakant Agrawal 及 Amr El Abbadi。2000。基于向量逼近的非均匀高维数据集索引方法。载于*《第九届信息与知识管理国际会议论文集》*（美国弗吉尼亚州麦克莱恩）（*CIKM '00*）。美国计算机协会，纽约州纽约市，202–209页。https://doi.org/10.1145/354756.354820

[28] Casper Benjamin Freksen。2021。《Johnson-Lindenstrauss 变换导论》。*CoRR* abs/2103.00564 (2021)。arXiv:2103.00564 https://arxiv.org/abs/2103.00564

[29] Cong Fu 、 Changxu Wang 与 Deng Cai 。2021。基于卫星系统图的高维相似性搜索：效率、可扩展性及未索引查询兼容性。*《IEEE 模式分析与机器智能汇刊》*（2021）。

[30] Cong Fu 、 Chao Xiang 、 Changxu Wang 与 Deng Cai 。2019。基于导航式扩展图的快速近似最近邻搜索。*Proc. VLDB Endow.*12,5（2019年1月），461–474。https://doi.org/10.14778/3303753.3303754

[31] Junhao Gan 、 Jianlin Feng 、 Qiong Fang 与 Wilfred Ng 。2012。基于动态碰撞计数的局部敏感哈希方案。载于*《2012年 ACM SIGMOD 国际数据管理会议论文集》*（美国亚利桑那州斯科茨代尔）（*SIGMOD '12*）。美国计算机协会，纽约州纽约市，541–552页。https://doi.org/10.1145/2213836.2213898

[32] Jianyang Gao 与 Cheng Long 。2023。高维近似最近邻搜索：具备可靠且高效的距离比较操作。*《ACM 管理数据》*第 1 卷第 2 期，第 137 篇（2023 年 6 月），共 27 页。https://doi.org/10.1145/3589282

[33] Jianyang Gao 与 Cheng Long . 2024. RaBitQ：基于理论误差界的高维向量量化及近似最近邻搜索（技术报告）。https://github.com/gaoj0017/RaBitQ/technical_report.pdf。

[34] Tiezheng Ge 、 Kaiming He 、 Qifa Ke 与 Jian Sun 。2013。用于近似最近邻搜索的优化产物量化。载于*《IEEE 计算机视觉与模式识别会议论文集》*，第 2946–2953 页。

[35] Long Gong 、 Huayi Wang 、 Mitsunori Ogihara 及 Jun Xu 。2020。《 IDEC：用于近似最近邻搜索的可索引距离估计码》。*《 VLDB Endow. 会议论文集》*第 13 卷，第 9 页（2020 年 5 月），第 1483–1497 页。https://doi.org/10.14778/3397230.3397243

[36] Yunchao Gong 、 Svetlana Lazebnik 、 Albert Gordo 与 Florent Perronnin 。2013。迭代量化：一种用于大规模图像检索的二进制编码学习之普罗克鲁斯图斯方法。*IEEE 模式分析与机器智能汇刊* 35,12 (2013)，2916–2929。https://doi.org/10.1109/TPAMI.2012.193

[37] Ruiqi Guo 、 Philip Sun 、 Erik Lindgren 、 Quan Geng 、 David Simcha 、 Felix Chern 及 Sanjiv Kumar 。2020。利用各向异性向量量化加速大规模推理。载于*《第37届国际机器学习大会（ICML '20）论文集》*。JMLR.org，第364篇，共10页。

[38] Qiang Huang 、 Jianlin Feng 、 Yikai Zhang 、 Qiong Fang 及 Wilfred Ng 。2015。面向查询的局部敏感哈希算法用于近似最近邻搜索。*《 VLDB 基金会会议论文集》*第 9 卷第 1 期（2015），第 1–12 页。

[39] Piotr Indyk 与 Rajeev Motwani . 1998.《近似最近邻算法：应对维度灾难》。载于*《第30届 ACM 计算理论年度研讨会论文集》*，第 604–613 页。

[40] Piotr Indyk 、 Ilya Razenshteyn 与 Tal Wagner 。2017。具有可证明保证性的实用数据依赖型度量压缩。载于《*第31届神经信息处理系统国际会议论文集*》（美国加利福尼亚州长滩）（*NIPS '17*）。Curran Associates Inc.，美国纽约州红钩，2614–2623。

[41] Piotr Indyk 与 Tal Wagner。2022。最优（欧氏）度量压缩。*SIAM J. Comput.*51,3 (2022)，467–491。https://doi.org/10.1137/20M1371324 arXiv:https://doi.org/10.1137/20M1371324

[42] Junhyeok Jang 、 Hanjin Choi 、 Hanyeoreum Bae 、 Seungjun Lee 、 Miryeong Kwon 及 Myoungsoo Jung 。2023。《 CXL - ANNS： 面向百亿级近似最近邻搜索的软件-硬件协同内存解耦与计算》。载于*2023年 USENIX 年度技术会议（USENIX ATC 23）*。 USENIX 协会，马萨诸塞州波士顿，585–600页。https://www.usenix.org/conference/atc23/presentation/jang

[43] Yahoo Japan。2022。 NGT -QG。https://github.com/yahoojapan/ NGT。

[44] Suhas Jayaram Subramanya，Fnu Devvrit，Harsha Vardhan Simhadri，Ravishankar Krishnawamy，及 Rohan Kadekodi 。2019。DiskANN：在单个节点上快速、准确地执行十亿点最近邻搜索。载于《*神经信息处理系统进展*》，H. Wallach、H. Larochelle、A. Beygelzimer、F. d 'Alche-Buc、E. Fox 与 R. Garnett 编，第 32 卷。Curran Associates，Inc.。https://proceedings.neurips.cc/paper/2019/file/09853c7fb1d3f8ee67a61b6bf4a7f8e6-Paper.pdf

[45] Herve Jegou 、 Matthijs Douze 与 Cordelia Schmid 。2010。用于最近邻搜索的产物量化。《*IEEE 模式分析与机器智能汇刊*》第 33 卷，第 1 期（2010），第 117–128 页。

[46] Jianqiu Ji 、 Jianmin Li 、 Shuicheng Yan 、 Bo Zhang 及 Qi Tian 。2012。超位局部敏感哈希。载于《*第25届神经信息处理系统国际会议论文集——第1卷*》（内华达州太浩湖）（*NIPS '12*）。Curran Associates Inc.，美国纽约州红钩区，第108–116页。

[47] Wenqi Jiang，Shigang Li，Yu Zhu，Johannes De Fine Licht，Zhenhao He，Runbin Shi，Cedric Renggli，Shuai Zhang，Theodoros Rekatsinas，Torsten Hoefler，与 Gustavo Alonso 。2023。面向向量搜索的硬件与算法协同设计。载于《*国际高性能计算、网络、存储与分析会议论文集*》（美国科罗拉多州丹佛市）（*SC '23*）。美国计算机协会，纽约州纽约市，第87页，共15页。https://doi.org/10.1145/3581784.3607045

[48] Jef Johnson 、 Matthijs Douze 与 Herve Jegou 。2019。基于 GPU 的百亿级相似性搜索。*IEEE 大数据汇刊*7,3 (2019)，535–547。

[49] William B. Johnson 与 Joram Lindenstrauss。1984。《Lipschitz 映射在希尔伯特空间中的延拓》第 26 页。《*当代数学*》第 26 卷（1984 年），第 28 页。

[50] Daniel M.Kane 与 Jelani Nelson . 2014.《稀疏版 Johnson-Lindenstrauss 变换》.《*J. ACM*》第 61 卷,第 1 期,第 4 篇(2014 年 1 月),共 23 页.https://doi.org/10.1145/2559902

[51] Keegan Kang 与 Weipin Wong . 2018. 利用附加信息改进符号随机投影。载于《*第35届机器学习国际会议论文集（《机器学习研究》第80卷）*》，Jennifer Dy 与 Andreas Krause（编）。 PMLR，第2479–2487页。https://proceedings.mlr.press/v80/kang18b.html

[52] V. I. Khokhlov. 2006.**Rs**中球面上的均匀分布——投影性质研究. I.*概率论及其应用* 50,3 (2006)，386–399.https://doi.org/10.1137/S0040585X97981846 arXiv:https://doi.org/10.1137/S0040585X97981846

[53] Kasper Green Larsen 与 Jelani Nelson . 2017.《Johnson-Lindenstrauss 引理的最优性》。载于*2017年 IEEE 第58届计算机科学基础年度研讨会（FOCS）*。IEEE，第633–638页。

[54] Yifan Lei 、 Qiang Huang 、 Mohan Kankanhalli 与 Anthony K. H. Tung 。2020。基于最长循环共子串的局部敏感哈希方案。载于《*2020年 ACM SIGMOD 国际数据管理会议论文集*》（美国俄勒冈州波特兰市）（*SIGMOD '20*）。美国计算机协会，纽约州纽约市，2589–2599页。https://doi.org/10.1145/3318464.3389778

[55] Conglong Li 、 Minjia Zhang 、 David G. Andersen 与 Yuxiong He 。2020。通过学习自适应早期终止优化近似最近邻搜索。载于《*2020年 ACM SIGMOD 国际数据管理会议论文集*》（美国俄勒冈州波特兰市）。美国计算机协会，纽约州纽约市，2539–2554页。https://doi.org/10.1145/3318464.3380600

[56] Jinfeng Li 、 Xiao Yan 、 Jian Zhang 、 An Xu 、 James Cheng 、 Jie Liu 、 Kelvin K. W. Ng 及 Cheng Ti-chung。2018。一种用于学习哈希的通用且高效的查询方法。载于《*2018年国际数据管理会议论文集*》（美国德克萨斯州休斯顿）（*SIGMOD '18*）。美国计算机协会，纽约州纽约市，1333–1347页。https://doi.org/10.1145/3183713.3183750

[57] Mingjie Li 、Yuan- Gen Wang 、 Peng Zhang 、 Hanpin Wang 、 Lisheng Fan 、 Enxia Li 及 Wei Wang 。2023。《基于深度学习的近似最近邻搜索：综述与未来方向》。*IEEE 知识与数据工程汇刊* 35,9 (2023)，8997–9018。https://doi.org/10.1109/ TKDE .2022.3220683

[58] Wen Li 、 Ying Zhang 、 Yifang Sun 、 Wei Wang 、 Mingjie Li 、 Wenjie Zhang 及 Xuemin Lin 。2019。高维数据上的近似最近邻搜索——实验、分析与改进。*IEEE 知识与数据工程汇刊*32,8 (2019)，1475–1488。

[59] Yingfan Liu 、 Hong Cheng 与 Jiangtao Cui 。2017。《 PQBF： 基于乘积量化的 I/O 高效近似最近邻搜索》。载于《*2017年 ACM 信息与知识管理会议论文集*》（新加坡，新加坡）（*CIKM '17*）。美国纽约州纽约市，计算机器协会，667–676页。https://doi.org/10.1145/3132847.3132901

[60] Ying Liu 、 Dengsheng Zhang 、 Guojun Lu 及 Wei- Ying Ma 。2007。基于高层语义的内容图像检索综述。*Pattern Recognition* 40,1 (2007)，262–282。https://doi.org/10.1016/j.patcog.2006.04.045

[61] Zihan Liu 、 Wentao Ni 、 Jingwen Leng 、 Yu Feng 、 Cong Guo 、 Quan Chen 、 Chao Li 、 Minyi Guo 及 Yuhao Zhu 。2023。JUNO：基于稀疏感知算法与射线追踪核心映射的高维近似最近邻搜索优化。arXiv:2312.01712[cs. DC]

[62] Kejing Lu 、 Mineichi Kudo 、 Chuan Xiao 及 Yoshiharu Ishikawa 。2021。《 HVS： 基于 Voronoi 图的层次化图结构用于近似最近邻搜索》。*Proc. VLDB Endow.*15,2（2021年10月），246–258。https://doi.org/10.14778/3489496.3489506

[63] Kejing Lu 、 Hongya Wang 、 Wei Wang 与 Mineichi Kudo 。2020。《 VHP： 基于虚拟超球面划分的近似最近邻搜索》。《*VLDB 捐赠会论文集*》第 13 卷，第 9 页（2020），第 1443–1455 页。

[64] Yury Malkov 、 Alexander Ponomarenko 、 Andrey Logvinov 及 Vladimir Krylov 。2014。基于可导航小世界图的近似最近邻算法。《*信息系统*》45 (2014)，61–68。https://doi.org/10.1016/j.is.2013.10.006

[65] Yu A.Malkov 与 D. A. Yashunin.2020.基于分层可导航小世界图的高效且鲁棒的近似最近邻搜索.*IEEE 模式分析与机器智能汇刊*42,4 (2020),824–836.https://doi.org/10.1109/TPAMI.2018.2889473

[66] Julieta Martinez 、 Joris Clement 、 Holger H. Hoos 与 James J. Little 。2016。《重新审视加法量化》。载于《*计算机视觉——ECCV 2016*》，Bastian Leibe、Jiri Matas、Nicu Sebe 及 Max Welling（编）。Springer International Publishing，Cham，第 137–153 页。

[67] Julieta Martinez 、 Shobhit Zakhmi 、 Holger H. Hoos 与 James J. Little 。2018。《 LSQ ++：多码本量化中的更低运行时间与更高召回率》。载于《*计算机视觉 – ECCV 2018：第15届欧洲会议，德国慕尼黑，2018年9月8–14日，论文集第 XVI 部分*》（德国慕尼黑）。Springer-Verlag，柏林、海德堡，第 508–523 页。https://doi.org/10.1007/978-3-030-01270-0_30

[68] Yusuke Matsui 、 Yusuke Uchida 、 Herve Jegou 及 Satoh Shin 'ichi。2018。《产品量化综述》。*ITE 媒体技术与应用学报* 第 6 卷第 1 期（2018），第 2–10 页。

[69] Jason Mohoney 、 Anil Pacaci 、 Shihabur Rahman Chowdhury、 Ali Mousavi 、 Ihab F. Ilyas 、 Umar Farooq Minhas、 Jefrey Pound 及 Theodoros Rekatsinas 。2023。知识图谱中的高吞吐量向量相似度搜索。《*ACM 管理数据*》第 1 卷第 2 期，第 197 篇（2023 年 6 月），共 25 页。https://doi.org/10.1145/3589777

[70] Rajeev Motwani 与 Prabhakar Raghavan。1995。《*随机算法*》。剑桥大学出版社。https://doi.org/10.1017/CBO9780511814075

[71] Marius Muja 与 David G. Lowe。2014。适用于高维数据的可扩展最近邻算法。《*IEEE 模式分析与机器智能汇刊*》第 36 卷，第 11 期（2014），第 2227–2240 页。

[72] Rasmus Pagh 与 Johan Sivertsen 。2020。内积过滤器的空间复杂度。载于《*第23届国际数据库理论会议（ICDT 2020）（莱布尼茨信息学国际会议论文集，第155卷）*》，Carsten Lutz 与 Jean Christoph Jung（编）。德国达格斯图尔–莱布尼茨信息学中心，第22:1–22:14页。https://doi.org/10.4230/LIPIcs. ICDT .2020.22

[73] John Paparrizos 、 Ikraduya Edian 、 Chunwei Liu 、 Aaron J. Elmore 及 Michael J. Franklin 。2022。基于方差感知量化的快速自适应相似性搜索。载于*2022年第38届IEEE 数据工程国际会议（ICDE）*，第2969–2983页。https://doi.org/10.1109/ICDE53745.2022.00268

[74] Yun Peng 、 Byron Choi 、 Tsz Nam Chan、 Jianye Yang 及 Jianliang Xu 。2023。多维数据库中的高效近似最近邻搜索。《*ACM 管理数据*》第 1 卷第 1 期，第 54 篇（2023 年 5 月），共 27 页。https://doi.org/10.1145/3588908

[75] Jianbin Qin，Wei Wang，Chuan Xiao，Ying Zhang，及 Yaoshu Wang 。2021。《数据科学中的高维相似性查询处理》。载于《*第27届 ACM SIGKDD 知识发现与数据挖掘会议论文集*》（虚拟会议，新加坡）（*KDD '21*）。美国纽约州纽约市，ACM 出版公司，第 4062–4063 页。https://doi.org/10.1145/3447548.3470811

[76] Hanan Samet . 2005.《*多维与度量数据结构基础》（Morgan Kaufmann 计算机图形学与几何建模丛书）*。Morgan Kaufmann Publishers Inc.，美国加利福尼亚州旧金山。

[77] J. Ben Schafer 、 Dan Frankowski 、 Jon Herlocker 与 Shilad Sen 。2007。《*协同过滤推荐系统*》。Springer 柏林-海德堡出版社，柏林，海德堡，第 291–324 页。https://doi.org/10.1007/978-3-540-72079-9_9

[78] Yifang Sun 、 Wei Wang 、 Jianbin Qin 、 Ying Zhang 及 Xuemin Lin 。2014。《SRS：利用微型索引在高维欧氏空间中解决 c-近似最近邻查询》。《*VLDB 捐赠会议论文集*》（2014）。

[79] Yufei Tao 、 Ke Yi 、 Cheng Sheng 与 Panos Kalnis 。2010。高维空间中高效且精确的最近邻及最近点对搜索。*ACM 数据库系统交易期刊 (TODS)*35,3 (2010)，1–46。

[80] Y. Tian、X. Zhao 与 X. Zhou。2022。DB- LSH： 基于查询的动态分桶的局部敏感哈希。载于*2022年第38届IEEE数据工程国际会议（ICDE）*。IEEE计算机学会，美国加利

福尼亚州洛斯阿拉米托斯，2250–2262 页。https://doi.org/10.1109/ICDE53745.2022.00214

[81] Ertem Tuncel、Hakan Ferhatosmanoglu 与 Kenneth Rose。2002。《VQ-Index：多媒体数据库中相似性检索的索引结构》。载于《*第十届 ACM 国际多媒体会议论文集*》（法国胡安-莱-潘斯）（*multimedia '02*）。美国纽约州纽约市，计算机器协会，第 543–552 页。https://doi.org/10.1145/641007.641117

[82] Roman Vershynin. 2018.《*高维概率：数据科学应用导论*》。剑桥大学出版社。https://doi.org/10.1017/9781108231596

[83] Jun Wang、Wei Liu、Sanjiv Kumar 及 Shih-Fu Chang。2016。《大数据索引中的哈希学习——综述》。*Proc. IEEE* 104,1 (2016)，34–57。https://doi.org/10.1109/JPROC.2015.2487976

[84] Jianguo Wang，Xiaomeng Yi，Rentong Guo，Hai Jin，Peng Xu，Shengjun Li，Xiangyu Wang，Xiangzhou Guo，Chengming Li，Xiaohai Xu，Kun Yu，Yuxing Yuan，Yinghao Zou，Jiquan Long，Yudong Cai，Zhenxiang Li，Zhifeng Zhang，Yihua Mo，Jun Gu，Ruiyi Jiang，Yi Wei，与 Charles Xie。2021。《Milvus：一款专为向量数据管理打造的系统》。载于《*2021年国际数据管理会议论文集*》（虚拟会议，中国）（*SIGMOD '21*）。美国纽约州纽约市，ACM 出版公司，第 2614–2627 页。https://doi.org/10.1145/3448016.3457550

[85] Jingdong Wang、Ting Zhang、jingkuan song、Nicu Sebe 及 Heng Tao Shen。2018。《学习哈希算法综述》。《*IEEE 模式分析与机器智能汇刊*》第 40 卷第 4 期（2018），第 769–790 页。https://doi.org/10.1109/TPAMI.2017.2699960

[86] Mengzhao Wang、Xiaoliang Xu、Qiang Yue 及 Yuxiang Wang。2021。基于图的近似最近邻搜索的全面调研与实验对比。*Proc. VLDB Endow.*14,11（2021年7月），1964–1978。https://doi.org/10.14778/3476249.3476255

[87] Yifan Wang、Haodi Ma 与 Daisy Zhe Wang。2022。LIDER：一种用于大规模密集段落检索的高效高维学习索引。*Proc. VLDB Endow.*16,2（2022年10月），154–166。https://doi.org/10.14778/3565816.3565819

[88] Zeyu Wang、Peng Wang、Themis Palpanas 与 Wei Wang。2023。《基于图与树的高维向量相似度搜索索引：分析、比较与未来方向》。*数据工程*（2023），第 3–21 页。

[89] Zeyu Wang、Qitong Wang、Peng Wang、Themis Palpanas 及 Wei Wang。2023。《Dumpy：适用于大型数据序列集合的紧凑且自适应索引》。《*ACM 数据管理会议论文集*》第 1 卷，第 1 期（2023），第 1–27 页。

[90] Roger Weber、Hans-Jorg Schek 与 Stephen Blott。1998。高维空间中相似性搜索方法的定量分析与性能研究。载于《*第24届超大规模数据库国际会议（VLDB '98）论文集*》。Morgan Kaufmann Publishers Inc.，美国加利福尼亚州旧金山，194–205页。

[91] Shitao Xiao，Zheng Liu，Weihao Han，Jianjin Zhang，Defu Lian，Yeyun Gong，Qi Chen，Fan Yang，Hao Sun，Yingxia Shao，与 Xing Xie。2022。Distill-VQ：通过从密集嵌入中学习知识，实现检索导向的向量量化。载于《*第45届 ACM SIGIR 信息检索研究与开发国际会议论文集*》（西班牙马德里）（*SIGIR '22*）。ACM，美国纽约州纽约市，1513–1523 页。https://doi.org/10.1145/3477495.3531799

[92] Wen Yang、Tao Li、Gai Fang 与 Hong Wei。2020。PASE：PostgreSQL 超高维近似最近邻搜索扩展。载于《*2020年 ACM SIGMOD 国际数据管理会议论文集*》（美国俄勒冈州波特兰市）（*SIGMOD '20*）。美国纽约州纽约市计算机协会，2241–2253页。https://doi.org/10.1145/3318464.3386131

[93] R. Zamir 与 M. Feder。1992。关于采用随机均匀量化器/格点量化器进行通用量化的研究。*IEEE 信息论汇刊* 38,2 (1992)，428–436。https://doi.org/10.1109/18.119699

[94] Pavel Zezula、Giuseppe Amato、Vlastislav Dohnal 与 Michal Batko。2010。《*相似性搜索：度量空间方法*》（第一版）。Springer Publishing Company，Incorporated。

[95] Ting Zhang，Chao Du，与 Jingdong Wang。2014。近似最近邻搜索中的复合量化。载于《*第31届国际机器学习会议论文集（机器学习研究论文集，第32卷）*》，Eric P. Xing 与 Tony Jebara 编著。北京，中国，PMLR 出版社，第838–846页。https://proceedings.mlr.press/v32/zhangd14.html

[96] Xi Zhao，Yao Tian，Kai Huang，Bolong Zheng，及 Xiaofang Zhou。2023。高维空间中高效索引构建与近似最近邻搜索研究。*Proc. VLDB Endow.*16,8（2023年6月），1979–1991。https://doi.org/10.14778/3594512.3594527

[97] Bolong Zheng、Zhao Xi、Lianggui Weng、Nguyen Quoc Viet Hung、Hang Liu 及 Christian S Jensen。2020。PM-LSH：一种用于高维近似神经网络搜索的快速且精确的 LSH 框架。《*VLDB 捐赠会论文集*》第 13 卷第 5 期（2020），第 643–655 页。

附录

A 引理3.1的证明

证明：当**o**与**q**共线时，即**q**= _**o**或**q**=**o**，公式（9）可直接由定义验证；当**o**与**q**不共线时，它们可被包含于一个二维子空间中。我们首先在该子空间中选取一对（相互正交的）单位坐标向量，即**o**与$\mathbf{e}_1 := \frac{\mathbf{q}-\langle \mathbf{q},\mathbf{o}\rangle \mathbf{o}}{\|\mathbf{q}-\langle \mathbf{q},\mathbf{o}\rangle \mathbf{o}\|}$，可通过以下方式验证

$$\langle \mathbf{o}, \mathbf{e}_1\rangle = \left\langle \mathbf{o}, \frac{\mathbf{q}-\langle \mathbf{q},\mathbf{o}\rangle \mathbf{o}}{\|\mathbf{q}-\langle \mathbf{q},\mathbf{o}\rangle \mathbf{o}\|}\right\rangle = \frac{\langle \mathbf{q},\mathbf{o}\rangle - \langle \mathbf{q},\mathbf{o}\rangle \cdot \|\mathbf{o}\|^2}{\|\mathbf{q}-\langle \mathbf{q},\mathbf{o}\rangle \mathbf{o}\|} = 0 \tag{23}$$

接下来，我们基于坐标向量**o**与$\mathbf{e}_1$，对$\bar{\mathbf{o}}$及**q**进行如下分解。

$$\bar{\mathbf{o}} = (\bar{\mathbf{o}} - \langle \bar{\mathbf{o}},\mathbf{o}\rangle \mathbf{o} - \langle \bar{\mathbf{o}},\mathbf{e}_1\rangle \mathbf{e}_1) + \langle \bar{\mathbf{o}},\mathbf{o}\rangle \mathbf{o} + \langle \bar{\mathbf{o}},\mathbf{e}_1\rangle \mathbf{e}_1 \tag{24}$$

$$\mathbf{q} = \langle \mathbf{q},\mathbf{o}\rangle \mathbf{o} + \langle \mathbf{q},\mathbf{e}_1\rangle \mathbf{e}_1 \tag{25}$$

其中（25）是因为**q**位于该子空间中。接着，由于（$\bar{\mathbf{o}}$_〈$\bar{\mathbf{o}}$，**o**〉**o**_〈$\bar{\mathbf{o}}$，$\mathbf{e}_1$〉$\mathbf{e}_1$）与该子空间正交，且**o** ⊥ $\mathbf{e}_1$，可得：

$$\langle \bar{\mathbf{o}},\mathbf{q}\rangle = \langle \bar{\mathbf{o}},\mathbf{o}\rangle \cdot \langle \mathbf{o},\mathbf{q}\rangle + \langle \bar{\mathbf{o}},\mathbf{e}_1\rangle \cdot \langle \mathbf{q},\mathbf{e}_1\rangle \tag{26}$$

$$= \langle \bar{\mathbf{o}},\mathbf{o}\rangle \cdot \langle \mathbf{o},\mathbf{q}\rangle + \langle \bar{\mathbf{o}},\mathbf{e}_1\rangle \cdot \sqrt{1-\langle \mathbf{o},\mathbf{q}\rangle^2} \tag{27}$$

其中 (27) 源于勾股定理。 □

B 浓度现象分析

在本节中，我们对第3.2.1节中提出的集中现象进行严格分析。具体而言，我们将分析〈$\bar{\mathbf{o}}$，**o**〉的期望值（第B.1节）、〈$\bar{\mathbf{o}}$，**o**〉的集中程度（第B.2节）以及〈$\bar{\mathbf{o}}$，**o**〉与〈$\bar{\mathbf{o}}$，$\mathbf{e}_1$〉的联合分布（第B.3节）。我们将这些结论汇总于引理B.3中，并在图8中进行实证验证。

B.1 〈$\bar{\mathbf{o}}$，**o**〉的期望值

如第3.2.1节所述，〈$\bar{\mathbf{o}}$，**o**〉与〈$\bar{\mathbf{o}}$，$\mathbf{e}_1$〉分别对应随机向量$\bar{\mathbf{o}}$在两个相互正交方向上的投影。为分析这些随机变量的联合分布，我们首先重新审视$\bar{\mathbf{o}}$的生成过程。$\bar{\mathbf{o}}$的生成包含两个步骤：第一步，算法通过随机正交变换P将确定性码本C随机转换为Crand；第二步，从Crand中的向量里选取与**o**内积最大的向量$\bar{\mathbf{o}}$。接下来，我们根据〈$\bar{\mathbf{o}}$，**o**〉的定义（生成过程）推导出如下结论。

$$\langle \bar{\mathbf{o}},\mathbf{o}\rangle = \max_{\mathbf{x}\in C} \langle P\mathbf{x},\mathbf{o}\rangle \tag{28}$$

$$= \max_{\mathbf{x}\in C} \left\langle \mathbf{x}, P^{-1}\mathbf{o}\right\rangle = \max_{\mathbf{x}\in C} \sum_{i=1}^{D} \mathbf{x}[i]\cdot (P^{-1}\mathbf{o})[i] \tag{29}$$

$$= \frac{1}{\sqrt{D}} \sum_{i=1}^{D} \left|(P^{-1}\mathbf{o})[i]\right| = \frac{1}{\sqrt{D}} \|P^{-1}\mathbf{o}\|_{\ell_1} \tag{30}$$

其中式 (28) 源于$\bar{\mathbf{o}}$的生成过程；而式 (29) 则是因为内积在正交变换（旋转）下保持不变。

(30) is due to the definition of our codebook C and the definition of ℓ_1 norm. Specifically, as is analyzed in Section 3.1.3, the entry of $\mathbf{x} \in$ C can only be $1/\sqrt{D}$ or $-1/\sqrt{D}$. To maximize the inner product, we only need to pick the **x** which has its signs of the entries match the vector $P^{-1}\mathbf{o}$. Thus, the result of the inner product is the summation the absolute values as is presented in (30), where $\|\cdot\|_{\ell_1}$表示ℓ_1范数。

我们注意到**o**是一个单位向量。P是一个随机正交变换矩阵（即随机旋转矩阵），其逆矩阵（逆旋转矩阵）同样是一个随机正交变换矩阵。因此，向量$P^{-1}\mathbf{o}$在D维空间RD中服从单位球面$\mathcal{S}_{-1}$上的均匀分布。该分布已被充分研究[52, 82]。借助以下引理，我们重新陈述关于该分布的若干结论。

引理 B.1.*([52, 82]) 对于在单位球面上服从均匀分布的 D 维随机向量***x**=(**x**[1]，**x**[2]，…，**x**[D])，*其每个坐标***x**[1]，**x**[2]，…，**x**[D] 的概率密度函数如下所示：*

$$p_D(x) = \frac{\Gamma(\frac{D}{2})}{\sqrt{\pi}\Gamma(\frac{D-1}{2})}(1-x^2)^{\frac{D-3}{2}}, x \in [-1,1] \tag{31}$$

*其中*Γ（·）*为伽马函数。其尾界表达式如下：*

$$\mathbb{P}\left\{|\mathbf{x}[i]| > \frac{t}{\sqrt{D}}\right\} \le 2\exp\left(-c_0 t^2\right) \tag{32}$$

其中c_0*为常数，* i =1，2，…，D。

基于概率密度函数的显式表达式，我们接下来按如下方式推导〈$\bar{\mathbf{o}}$，**o**〉的期望值。

$$\mathbb{E}\left[\langle \bar{\mathbf{o}},\mathbf{o}\rangle\right] = \frac{1}{\sqrt{D}} \cdot \mathbb{E}\left[\sum_{i=1}^{D} \left|(P^{-1}\mathbf{o})[i]\right|\right] \tag{33}$$

$$= \sqrt{D} \cdot \mathbb{E}\left[\left|(P^{-1}\mathbf{o})[1]\right|\right] \tag{34}$$

$$= \sqrt{\frac{D}{\pi}} \frac{\Gamma(\frac{D}{2})}{\Gamma(\frac{D-1}{2})} \cdot \int_{-1}^{1} (1-x^2)^{\frac{D-3}{2}} |x| \mathrm{d}x \tag{35}$$

$$= \sqrt{\frac{D}{\pi}} \frac{2\Gamma(\frac{D}{2})}{(D-1)\Gamma(\frac{D-1}{2})} \tag{36}$$

其中 (33) 源于 (30)；(34) 则源于期望的线性性质。
(35) 这由引理B.1可得。（36）则可通过初等微积分得出。

我们注意到，尽管〈$\bar{\mathbf{o}}$，**o**〉的期望值具有复杂形式（即式36），但其数值却高度稳定。当D取值范围为10^2至10^6时，该值介于0.798至0.800之间，这一结果与第3.2.1节中的观测数据完美吻合。

B.2 〈$\bar{\mathbf{o}}$，**o**〉的浓度

接下来，我们分析〈$\bar{\mathbf{o}}$，**o**〉的集中程度。回顾 (30) 式所示，〈$\bar{\mathbf{o}}$，**o**〉$= \frac{1}{\sqrt{D}}$聂$P^{-1}\mathbf{o}$聂ℓ_1。设$f(\mathbf{x}) := \frac{1}{\sqrt{D}}$聂**x**聂$\ell_1$。则有〈$\bar{\mathbf{o}}$，**o**〉$= f(P^{-1}\mathbf{o})$。我们注意到$f(\mathbf{x})$是一个利普希茨函数，其利普希茨常数为 1，即：

$$|f(\mathbf{x}) - f(\mathbf{y})| \le 1 \cdot \|\mathbf{x}-\mathbf{y}\| \tag{37}$$

对于单位球面上的每个**x**与**y**。

证明。

$$|f(\mathbf{x}) - f(\mathbf{y})| = \frac{1}{\sqrt{D}} \left| \|\mathbf{x}\|_{\ell_1} - \|\mathbf{y}\|_{\ell_1} \right| \tag{38}$$

$$\leq \frac{1}{\sqrt{D}} \|\mathbf{x} - \mathbf{y}\|_{\ell_1} = \frac{1}{\sqrt{D}} \sum_{i=1}^{D} 1 \cdot |\mathbf{x}[i] - \mathbf{y}[i]| \tag{39}$$

$$\leq \frac{1}{\sqrt{D}} \cdot \sqrt{\sum_{i=1}^{D} 1^2} \cdot \sqrt{\sum_{i=1}^{D} (\mathbf{x}[i] - \mathbf{y}[i])^2} = \|\mathbf{x} - \mathbf{y}\| \tag{40}$$

其中 (38) 由定义可得；(39) 由三角形不等式可得；(40) 则源于 Cauchy-Schwarz 不等式。 □

回顾可知，$p^{-1}\mathbf{o}$是一个服从单位球面上均匀分布的随机向量。文献[82]中有一个著名引理指出：将服从单位球面上均匀分布的随机向量通过一个 Lipschitz 函数，可得到一个高度集中的分布。具体结论如下所示。

引理 B.2.*([82]) 设* $\mathbf{x}$ *为服从单位球面上均匀分布的 D 维随机向量，且* $f(\mathbf{x})$ *为 Lipschitz 函数，其 Lipschitz 常数为 L。则有*

$$\mathbb{P}\left\{|f(\mathbf{x}) - \mathbb{E}\left[f(\mathbf{x})\right]| \geq t\right\} \leq 2\exp\left(-\frac{cDt^2}{L^2}\right) \tag{41}$$

其中 c 为常数。

将我们的$f(\mathbf{x})$代入，即可立即得到以下结果。

$$\mathbb{P}\left\{|\langle \bar{\mathbf{o}}, \mathbf{o}\rangle - \mathbb{E}\left[\langle \bar{\mathbf{o}}, \mathbf{o}\rangle\right]| \geq t\right\} \leq 2\exp\left(-cDt^2\right) \tag{42}$$

$$\mathbb{P}\left\{|\langle \bar{\mathbf{o}}, \mathbf{o}\rangle - \mathbb{E}\left[\langle \bar{\mathbf{o}}, \mathbf{o}\rangle\right]| \geq \frac{u}{\sqrt{D}}\right\} \leq 2\exp\left(-cu^2\right) \tag{43}$$

其中（43）是通过令$u=t\sqrt{D}$推导得出。该结论表明 $\langle \bar{\mathbf{o}}, \mathbf{o}\rangle$ 高度集中于其期望值附近，且以高概率不会偏离其期望值超过 $\Omega(1/\sqrt{D})$。

B.3 联合分布($\langle \bar{\mathbf{o}}, \mathbf{o}</sp_5\rangle$ ， $\langle \bar{\mathbf{o}}, \mathbf{e}_1\rangle$)

接下来我们分析 $\langle \bar{\mathbf{o}}, \mathbf{e}_1\rangle$ 的分布。需注意， $\langle \bar{\mathbf{o}}, \mathbf{o}\rangle$ 与 $\langle \bar{\mathbf{o}}, \mathbf{e}_1\rangle$ 的随机性均源于$\bar{\mathbf{o}}$的随机性（而p的随机性又是$\bar{\mathbf{o}}$随机性的基础）。这些随机变量彼此相关，这对后续分析不利。我们首先尝试通过以下方式消除这些随机变量间的相关性：将 $\langle \bar{\mathbf{o}}, \mathbf{e}_1\rangle$ 表示为 $\langle \bar{\mathbf{o}}, \mathbf{o}\rangle$ 的某个函数，以及一个与 $\langle \bar{\mathbf{o}}, \mathbf{o}\rangle$ 无关的随机变量。特别地，我们将证明($\langle \bar{\mathbf{o}}, \mathbf{o}\rangle$ ， $\langle \bar{\mathbf{o}}, \mathbf{e}_1\rangle$)的联合分布与以下分布完全相同：

$$\left(\langle \bar{\mathbf{o}}, \mathbf{o}\rangle, \sqrt{1 - \langle \bar{\mathbf{o}}, \mathbf{o}\rangle^2} \cdot X_1\right) \tag{44}$$

其中X_1服从引理B.1中p_{D-1}的分布，且与 $\langle \bar{\mathbf{o}}, \mathbf{o}\rangle$ 独立。

证明。设$\mathbf{u}_1$= (1,0,0 ，…，0)，$\mathbf{u}_2$= (0,1,0 ，…，0)。对于$\mathbf{o}$与$\mathbf{e}_1$，其中$\mathbf{o} \perp \mathbf{e}_1$，存在一个正交矩阵$U$，可将二者分别对齐至$\mathbf{u}_1$与$\mathbf{u}_2$，即$U_o$=$\mathbf{u}_1, U\mathbf{e}_1 = \mathbf{u}_2$。随后，将正交矩阵$U$作用于内积的两侧，可得 $\bar{\mathbf{x}}$= arg max$_x \in C$ $\langle U_p x, \mathbf{u}_1\rangle$ ， $\langle p\bar{\mathbf{x}}, \mathbf{o}\rangle = \langle U_p\bar{\mathbf{x}}, \mathbf{u}_1\rangle$ ，以及 $\langle p\bar{\mathbf{x}}, \mathbf{e}_1\rangle = \langle U_p\bar{\mathbf{x}}, \mathbf{u}_2\rangle$ 。因此，为证明原命题，只需证明 ($\langle U_p\bar{\mathbf{x}}, \mathbf{u}_1\rangle$ ， $\langle U_p\bar{\mathbf{x}}, \mathbf{u}_2\rangle$) 的联合分布与以下分布相同：

$$\left(\langle UP\bar{\mathbf{x}}, \mathbf{u}_1\rangle, \sqrt{1 - \langle UP\bar{\mathbf{x}}, \mathbf{u}_1\rangle^2} \cdot X_1\right) \tag{45}$$

其中X_1与 $\langle Up\bar{\mathbf{x}}, \mathbf{u}_1\rangle$ 独立，且$X_1 \sim p_{D_1}$。由于随机正交变换具有旋转不变性——即Up的分布与p的分布相同——我们可以将所有Up替换为p。此时，原命题将转化为与原始命题相同的形式，只需将$\mathbf{o}$与$\mathbf{e}_1$分别替换为$\mathbf{u}_1$和$\mathbf{u}_2$。因此，为证明一般$\mathbf{o}$与$\mathbf{e}_1$情形下的命题，只需在不失一般性的前提下，证明$\mathbf{o}$=$\mathbf{u}_1$且$\mathbf{e}_1 = \mathbf{u}_2$时的情况即可。接下来，我们证明of $\mathbf{u}_1, \mathbf{u}_2$的情形。

我们考虑基于延迟决策原则[70]来分析分布。延迟决策原则的基本思想是：对于需要抽取若干随机数的随机算法，我们假设采样操作发生在算法访问这些采样数时，而非在初始阶段进行。在我们的案例中，我们将抽取一个随机正交矩阵p。该矩阵的生成过程包括：抽取$D \times D$个标准高斯随机变量作为其元素，然后使用格拉姆-施密特正交化方法对矩阵进行正交化。需要注意的是，格拉姆-施密特正交化是按行依次进行的。特别地，假设p的前i_1行，即$\mathbf{p_1}$，…，$\mathbf{p}_{i\ 1}$，已进行正交化（即$\mathbf{p_j} \perp \mathbf{p_k}$，且$\mathbf{p_j} \cdot \mathbf{p_k}$= 0）。

$$\mathbf{p}_i = \frac{\mathbf{g} - \sum_{j=1}^{i-1} \langle \mathbf{g}, \mathbf{p}_j\rangle \mathbf{p}_j}{\left\|\mathbf{g} - \sum_{j=1}^{i-1} \langle \mathbf{g}, \mathbf{p}_j\rangle \mathbf{p}_j\right\|} \tag{46}$$

其中 g 的每个元素均从标准高斯分布中采样。因此，基于 Gram–Schmidt 正交化过程，该采样过程可被视为一个包含D步的序贯过程，在每一步中我们采样一行新向量。

在我们的算法中，我们注意到 ($\langle p\bar{\mathbf{x}}, \mathbf{u}_1\rangle$ ， $\langle p\bar{\mathbf{x}}, \mathbf{u}_2\rangle$) 的联合分布仅依赖于p的前两行。首先对p的第一行进行采样，即$\mathbf{p}\ \mathbf{1}$。随后$\bar{\mathbf{x}}$即可确定，因为

$$\bar{\mathbf{x}} = \arg\max_{\mathbf{x} \in C} \langle P\mathbf{x}, \mathbf{u}_1\rangle = \arg\max_{\mathbf{x} \in C} \left\langle \mathbf{x}, P^{-1}\mathbf{u}_1\right\rangle \tag{47}$$

$$= \arg\max_{\mathbf{x} \in C} \left\langle \mathbf{x}, P^{\top}\mathbf{u}_1\right\rangle = \arg\max_{\mathbf{x} \in C} \langle \mathbf{x}, \mathbf{p}_1\rangle \tag{48}$$

其中（48）是因为正交矩阵的逆等于其转置。对于固定的$\bar{\mathbf{x}}$，我们接下来分析 $\langle p\bar{\mathbf{x}}, \mathbf{u}_2\rangle$ 的分布。我们注意到，类似地，该分布仅依赖于p的前两行，因为 $\langle p\bar{\mathbf{x}}, \mathbf{u}_2\rangle = \langle \bar{\mathbf{x}}, \mathbf{p_2}\rangle$ （注意$\bar{\mathbf{x}}$依赖于$\mathbf{p_1}$）。对于向量$\mathbf{p_1}$与$\bar{\mathbf{x}}$，存在一个正交矩阵V，可将二者对齐至$\underline{\mathrm{n}\ \mathbf{v}_1 =}(1, 0, 0, \ldots, 0)$and $\mathbf{v}_2 = (\langle \bar{\mathbf{x}}, {}_{\mathrm{p_1}}\rangle, \sqrt{(1 - \langle \bar{\mathbf{x}}, {}_{\mathrm{p_1}}\rangle^2}, 0, \ldots, 0)$，即$\mathbf{v}_1 = Vp_1$且$\mathbf{v}_2 = V\bar{\mathbf{x}}$。于是

$$\langle \bar{\mathbf{x}}, \mathbf{p}_2\rangle = \left\langle \bar{\mathbf{x}}, \frac{\mathbf{g} - \langle \mathbf{g}, \mathbf{p_1}\rangle \mathbf{p_1}}{\|\mathbf{g} - \langle \mathbf{g}, \mathbf{p_1}\rangle \mathbf{p_1}\|} \right\rangle \tag{49}$$

$$= \left\langle V\bar{\mathbf{x}}, \frac{V\mathbf{g} - \langle V\mathbf{g}, V\mathbf{p_1}\rangle V\mathbf{p_1}}{\|V\mathbf{g} - \langle V\mathbf{g}, V\mathbf{p_1}\rangle V\mathbf{p_1}\|} \right\rangle \tag{50}$$

$$= \left\langle \mathbf{v}_2, \frac{\mathbf{g} - \langle \mathbf{g}, \mathbf{v_1}\rangle \mathbf{v_1}}{\|\mathbf{g} - \langle \mathbf{g}, \mathbf{v_1}\rangle \mathbf{v_1}\|} \right\rangle \tag{51}$$

其中（49）通过Gram-Schmidt正交规范化实现。（50）是因为内积与欧氏距离对正交变换具有不变性。（51）是因为标准高斯随机向量具有旋转不变性[82]，即vg与$\mathbf{g}$具有相同的分布。我们注意到$\mathbf{v}_1$仅其第一个分量非零。因此，$\mathbf{g}\cdot\langle\mathbf{g},\mathbf{v}_1\rangle\mathbf{v}_1$的第一个维度为0，其余$D_1$个维度均为独立的标准高斯变量。经归一化后，剩余的$D_1$个维度在（$D_1$）维空间中服从单位球面上的均匀分布，且与$\mathbf{p}_1$独立。回顾that $\mathbf{v}_2=(\langle\mathbf{p}_1,\bar{\mathbf{x}}\text{<sp_20}\rangle,\sqrt{1\cdot\langle\mathbf{p}_1,\bar{\mathbf{x}}\text{<sp_25}\rangle^2},0,\ldots,0)$。故$\langle\bar{\mathbf{x}},\mathbf{p}_2\rangle=\sqrt{1-\langle\mathbf{p}_1,\bar{\mathbf{x}}\rangle^2}\cdot x_1$，其中$x_1$服从of p_{D-1}的分布。□

我们通过以下引理，总结关于$\langle\langle\bar{\mathbf{o}},\mathbf{o}\rangle,\langle\langle\bar{\mathbf{o}},\mathbf{e}_1\rangle\rangle$分布的结论。

引理 B.3（分布）。*设$\mathbf{o}$与$\mathbf{e}_1$为两个单位向量，且满足$\mathbf{o}\perp\mathbf{e}_1$。令$P$为随机正交变换矩阵，$C$为所构建的确定性码本，$\bar{\mathbf{x}}=\arg\max_{x\in C}\langle Px,\mathbf{o}\rangle$，$\bar{\mathbf{o}}=P\bar{\mathbf{x}}$。则$(\langle\bar{\mathbf{o}},\mathbf{o}\rangle,\langle\bar{\mathbf{o}},\mathbf{e}_1\rangle)$的联合分布与以下随机变量的联合分布相同:*

$$\left(\langle\bar{\mathbf{o}},\mathbf{o}\rangle,\sqrt{1-\langle\bar{\mathbf{o}},\mathbf{o}\rangle^2}\cdot X_1\right)\tag{52}$$

where X_1与$\langle\bar{\mathbf{o}},\mathbf{o}\rangle$ and $X_1\sim p_{D-1}$。$\langle\bar{\mathbf{o}},\mathbf{o}\rangle$的期望值为

$$\mathbb{E}\left[\langle\bar{\mathbf{o}},\mathbf{o}\rangle\right]=\sqrt{\frac{D}{\pi}}\cdot\frac{2\Gamma(\frac{D}{2})}{(D-1)\Gamma(\frac{D-1}{2})}\tag{53}$$

其中$\Gamma(\cdot)$为伽马函数，其集中界为

$$\mathbb{P}\left\{\left|\langle\bar{\mathbf{o}},\mathbf{o}\rangle-\mathbb{E}\left[\langle\bar{\mathbf{o}},\mathbf{o}\rangle\right]\right|>\frac{u}{\sqrt{D}}\right\}\leq 2\exp\left(-cu^2\right)\tag{54}$$

其中c为常数。

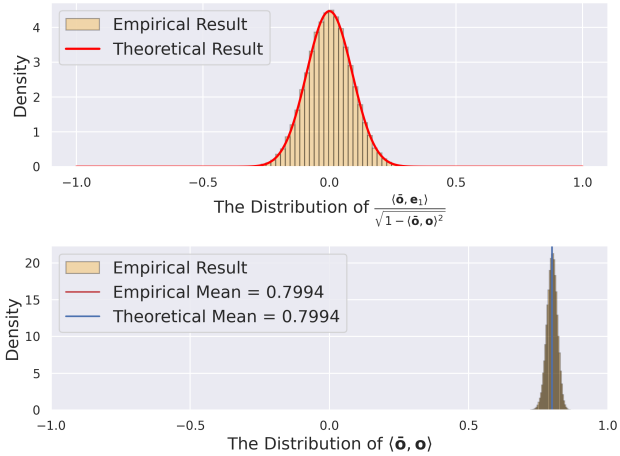


图 8：引理B.3的验证。

接下来，我们针对图8中的定理提供实证验证。首先，在图8的上部面板中，橙色直方图展示了基于105个样本的$\langle\bar{\mathbf{o}},\mathbf{e}_1\rangle/\sqrt{1-\langle\bar{\mathbf{o}},\mathbf{o}\rangle^2}$的实证分布。$P$的样本见第3.2.1节。根据(52)，它服从of p_{D-1}的分布。红色曲线绘制了引理B.1中规定的of p_{D-1}的理论密度函数。该曲线表明，经验结果与理论结果完全吻合，验证了本分析的正确性。其次，在图8的下半部分中，橙色直方图展示了基于前述105个样本得到的$\langle P\bar{\mathbf{x}},\mathbf{o}\rangle$的经验分布。该图显示$\langle P\bar{\mathbf{x}},\mathbf{o}\rangle$确实高度集中于其均值附近，且经验均值与理论期望值完全吻合，从而验证了我们的理论分析。

C 定理3.2的证明

基于上述引理，我们证明了该估计量的无偏性及误差界。

证明。我们首先证明无偏性。当$\mathbf{o}$与$\mathbf{q}$共线时，根据定义可直接验证无偏性；当$\mathbf{o}$与$\mathbf{q}$不共线时，为证明无偏性，只需证得公式(12)中估计量的误差项在期望下等于0。令$\mathbf{e}_1:=\frac{\mathbf{q}-\langle\mathbf{q},\mathbf{o}\rangle\mathbf{o}}{\|\mathbf{q}-\langle\mathbf{q},\mathbf{o}\rangle\mathbf{o}\|}$，则由E可得$\left[\frac{\langle\bar{\mathbf{o}},\mathbf{e}_1\rangle}{\langle\bar{\mathbf{o}},\mathbf{o}\rangle}\right]$具体如下。

$$\mathbb{E}\left[\frac{\langle\bar{\mathbf{o}},\mathbf{e}_1\rangle}{\langle\bar{\mathbf{o}},\mathbf{o}\rangle}\right]=\mathbb{E}\left[\sqrt{1-\langle\bar{\mathbf{o}},\mathbf{o}\rangle^2}\cdot X_1/\langle\bar{\mathbf{o}},\mathbf{o}\rangle\right]\tag{55}$$

$$=\mathbb{E}\left[\sqrt{1-\langle\bar{\mathbf{o}},\mathbf{o}\rangle^2}/\langle\bar{\mathbf{o}},\mathbf{o}\rangle\right]\cdot\mathbb{E}\left[X_1\right]\tag{56}$$

$$=\mathbb{E}\left[\sqrt{1-\langle\bar{\mathbf{o}},\mathbf{o}\rangle^2}/\langle\bar{\mathbf{o}},\mathbf{o}\rangle\right]\cdot 0=0\tag{57}$$

其中（55）由引理B.3得出；（56）源于$\langle\bar{\mathbf{o}},\mathbf{o}\rangle$与$X_1$之间的独立性；（57）则是因为of X_1的分布（即p_{D-1}）的期望为0。最后，基于（12），我们完成无偏性的证明。

随后，我们证明误差界。当$\mathbf{o}$与$\mathbf{q}$共线时，误差为零，如第3.2.2节所述。对于非共线情形，我们按如下方式证明误差界。

$$\mathbb{P}\left\{\left|\frac{\langle\bar{\mathbf{o}},\mathbf{q}\rangle}{\langle\bar{\mathbf{o}},\mathbf{o}\rangle}-\langle\mathbf{o},\mathbf{q}\rangle\right|>\sqrt{\frac{1-\langle\bar{\mathbf{o}},\mathbf{o}\rangle^2}{\langle\bar{\mathbf{o}},\mathbf{o}\rangle^2}}\cdot\frac{\epsilon_0}{\sqrt{D-1}}\right\}\tag{58}$$

$$=\mathbb{P}\left\{\sqrt{1-\langle\mathbf{o},\mathbf{q}\rangle^2}\left|\frac{\langle\bar{\mathbf{o}},\mathbf{e}_1\rangle}{\langle\bar{\mathbf{o}},\mathbf{o}\rangle}\right|>\sqrt{\frac{1-\langle\bar{\mathbf{o}},\mathbf{o}\rangle^2}{\langle\bar{\mathbf{o}},\mathbf{o}\rangle^2}}\cdot\frac{\epsilon_0}{\sqrt{D-1}}\right\}\tag{59}$$

$$\leq\mathbb{P}\left\{\left|\frac{\langle\bar{\mathbf{o}},\mathbf{e}_1\rangle}{\langle\bar{\mathbf{o}},\mathbf{o}\rangle}\right|>\sqrt{\frac{1-\langle\bar{\mathbf{o}},\mathbf{o}\rangle^2}{\langle\bar{\mathbf{o}},\mathbf{o}\rangle^2}}\cdot\frac{\epsilon_0}{\sqrt{D-1}}\right\}\tag{60}$$

$$=\mathbb{P}\left\{\sqrt{\frac{1-\langle\bar{\mathbf{o}},\mathbf{o}\rangle^2}{\langle\bar{\mathbf{o}},\mathbf{o}\rangle^2}}\cdot|X_1|>\sqrt{\frac{1-\langle\bar{\mathbf{o}},\mathbf{o}\rangle^2}{\langle\bar{\mathbf{o}},\mathbf{o}\rangle^2}}\cdot\frac{\epsilon_0}{\sqrt{D-1}}\right\}\tag{61}$$

$$=\mathbb{P}\left\{|X_1|>\frac{\epsilon_0}{\sqrt{D-1}}\right\}\leq 2e^{-c_0\epsilon_0^2}\tag{62}$$

其中（59）由引理3.1得出。（60）将$\sqrt{1-\langle\mathbf{o},\mathbf{q}\rangle^2}$放缩为1。（61）源自引理B.3。（62）应用引理B.1。□

表 5：B_q分析结果汇总。

	错误	Δ	总体误差	目标	B_q
琐碎的	$O(\sqrt{D}\cdot\Delta)$	$O(1/2^{B_q})$	$O(\sqrt{D}/2^{B_q})$	$O(1/\sqrt{D})$	$\Theta(\log D)$
我们的	$O(\Delta)$	$O(\sqrt{\frac{\log D}{D}}/2^{B_q})$	$O(\sqrt{\frac{\log D}{D}}/2^{B_q})$	$O(1/\sqrt{D})$	$\Theta(\log\log D)$

D B_q的分析

在本节中，我们证明：$B_q=\Theta(\log\log D)$ 足以保证均匀标量量化引入的误差远小于估计器本身的误差，即$O(1/\sqrt{D})$。我们分两步证明该命题。首先，我们将在第D.1节中证明均匀标量量化引入的误差为$O(\Delta)$（注意 $\Delta=(\max \mathbf{q},[i])-\min \mathbf{q},[i])/(2^{B_q}-1)$）。具体而言，回顾我们近似计算 $\langle\tilde{\mathbf{x}},\mathbf{q},\rangle$ 为 $\langle\tilde{\mathbf{x}},\tilde{\mathbf{q}}\rangle$。此时误差等于 $|\langle\tilde{\mathbf{x}},\tilde{\mathbf{q}}-\mathbf{q},\rangle|$。注意$\tilde{\mathbf{x}}$的各元素属于 $\pm 1/\sqrt{D}$，且$\tilde{\mathbf{q}}[i]-\mathbf{q},[i]\in[-\Delta,\Delta]$。通过三角不等式可得一个简单界：$|\langle\tilde{\mathbf{x}},\tilde{\mathbf{q}}-\mathbf{q},\rangle|\le D\cdot\frac{1}{\sqrt{D}}\cdot\Delta=\sqrt{D}\cdot\Delta$. 我们注意到，该界是宽松的，因为它未考虑低估与高估的抵消效应。我们将通过采用第3.3.1节中提出的随机均匀标量量化算法，并对该抵消效应进行定量分析，从而证明一个更强的概率界：$O(\Delta)$。其次，我们将证明：$\Delta=O(\sqrt{\frac{\log D}{D}}/2^{B_q})$ 在第D.2节中。回顾可知，$\mathbf{q}'=P^{-1}\mathbf{q}$ is a服从单位球面上均匀分布的随机向量。一个平凡界可得 $(\max \mathbf{q},[i])-\min \mathbf{q},[i])=O(1)$。我们注意到该界较为宽松，因为它未考虑$\mathbf{q}$各分量的集中现象（参见引理B.1）。接下来，我们将通过定量分析该集中现象，证明一个更强的概率界。

基于这两个概率界，我们通过应用并集界推导出整体误差。相关结论汇总于表5中。为使整体误差满足$O(1/\sqrt{D})$，可得$B_q=\Theta(\log\log D)$。值得注意的是，若仅基于平凡界，则需设定$B_q=\Theta(\log D)$才能保证相同的误差界，而该结果相较于本文结论的误差界呈指数级劣化。

D.1 随机均匀标量量化的误差

如前所述，均匀标量量化引入的误差为

$$\left|\left\langle\tilde{\mathbf{x}},\tilde{\mathbf{q}}-\mathbf{q}'\right\rangle\right|=\left|\sum_{i=1}^{D}\tilde{\mathbf{x}}[i]\cdot(\tilde{\mathbf{q}}[i]-\mathbf{q}'[i])\right| \tag{63}$$

由于第3.3.1节中所述的随机均匀标量量化，误差的每一项——即$\tilde{\mathbf{x}}[i]\cdot(\tilde{\mathbf{q}}[i]\mathbf{q},[i])$——均是一个随机变量。这$D$个随机变量彼此独立。每一项的期望值为0（参见第3.3.1节），且其取值被限制在$[-[-\Delta/\sqrt{D},+\Delta/\sqrt{D}]$内。现在的问题在于分析这$D$个随机变量的和。我们注意到，Hoeffding不等式可直接解答该问题[82]。我们将在以下引理中重新陈述该不等式。

引理 D.1（Hoeffding 不等式[82]）。*设 $X_1,\ldots,x_2$ 为相互独立的随机变量，且满足 $x_i\in[a_i,b_i]$，$\forall 1\le i\le n$。令 $S=\sum_{i=1}^{n}xi$. 然后*

$$\mathbb{P}\{|S_n-\mathbb{E}[S_n]|\ge t\}\le 2\exp\left(-\frac{2t^2}{\sum_{i=1}^{n}(b_i-a_i)^2}\right) \tag{64}$$

在本案例中，我们注意到$ai=-1/\sqrt{D}$，$bi=+1/\sqrt{D}$。$\mathbb{E}[s'']=\mathbb{E}\left[\sum_{i=1}^{n}X_i\right]=\sum_{i=1}^{n}\mathbb{E}[X_i]=0$。由此可直接得出以下结论。

$$\mathbb{P}\left\{\left|\sum_{i=1}^{D}\tilde{\mathbf{x}}[i]\cdot(\tilde{\mathbf{q}}[i]-\mathbf{q}'[i])\right|\ge t\right\}\le 2\exp\left(-\frac{t^2}{2\Delta^2}\right) \tag{65}$$

$$\mathbb{P}\left\{\left|\sum_{i=1}^{D}\tilde{\mathbf{x}}[i]\cdot(\tilde{\mathbf{q}}[i]-\mathbf{q}'[i])\right|\ge \Delta u\right\}\le 2\exp\left(-\frac{u^2}{2}\right) \tag{66}$$

其中 (66) 是通过令$u=t/$ 推导得出。该结论表明，以高概率，误差被$O()$ 所控制。

D.2 的分析

接下来，我们证明$\Delta=O(\sqrt{\frac{\log D}{D}}/2^{B_q})$ 以高概率成立。回顾定义：$=(\max_{1\le i\le D}\mathbf{q},[i])-\min_{1\le i\le D}\mathbf{q},[i])/(2^{B_q}-1)$。注意：$\max_{1\le i\le D}(\mathbf{q},[i])-\min_{1\le i\le D}(\mathbf{q},[i])\le 2\max_{1\le i\le D}|\mathbf{q},[i]|$。为证明原命题，只需证明 $\max_{1\le i\le D}|\mathbf{q}'[i]|=O(\sqrt{\frac{\log D}{D}})$ 以高概率成立，我们如下证明。

$$\mathbb{P}\left\{\max_{1\le i\le D}|\mathbf{q}'[i]|\ge\sqrt{\frac{\log D+t}{c_0 D}}\right\} \tag{67}$$

$$=\mathbb{P}\left\{\exists 1\le i\le D,|\mathbf{q}'[i]|\ge\sqrt{\frac{\log D+t}{c_0 D}}\right\} \tag{68}$$

$$\le D\cdot\mathbb{P}\left\{|\mathbf{q}'[1]|\ge\sqrt{\frac{\log D+t}{c_0 D}}\right\} \tag{69}$$

$$\le 2\exp\left(-c_0\cdot\frac{\log D+t}{c_0}+\log D\right)=2\exp(-t) \tag{70}$$

其中 (69) 由界估计法得出；(70) 由引理B.1得出。该结论表明 $\Delta=O(\sqrt{\frac{\log D}{D}}/2^{B_q})$ 以高概率。

E 关于标准化问题的探讨

我们注意到，当前我们的理论分析（对数据不作任何假设）给出了如[3]所述的加法误差界。令$dist'^2$表示基于本估计量得到的估计平方距离，其中$dist'^2=\|\mathbf{or_c}\|^2+\|\mathbf{qr_c}\|^2-\|\mathbf{or_c}\|\cdot\|\mathbf{qr_c}\|\cdot\frac{\langle\vec{\mathbf{o}},\vec{\mathbf{q}}\rangle}{\langle\vec{\mathbf{o}},\mathbf{o}\rangle}$考虑到我们并非使用质心对数据集进行归一化处理，而是使用空间原点进行归一化处理，则根据定理3.2中的公式 (15)，我们

可直接得出

$$\left|dist'^2 - \|\mathbf{o}_r - \mathbf{q}_r\|^2\right| = \|\mathbf{o}_r\| \cdot \|\mathbf{q}_r\| \cdot O\left(\frac{1}{\sqrt{D}}\right) \ w.h.p. \tag{71}$$

其中 "w.h.p." 是 "with high probability" 的缩写。

当数据向量经过良好归一化后，且在单位超球面上均匀分布时，我们假设经过归一化后的数据向量，即 $\mathbf{o} = \frac{\mathbf{o}_r - \mathbf{c}}{\|\mathbf{o}_r - \mathbf{c}\|}$，服从单位超球面上的均匀分布。由此可推导出以下推论，该推论给出了如[41]所述的乘法误差界。

CoRoLLARy E.1. *假设* **o** *服从单位超球面上的均匀分布，则有*

$$\left|\frac{dist'^2 - \|\mathbf{o}_r - \mathbf{q}_r\|^2}{\|\mathbf{o}_r - \mathbf{q}_r\|^2}\right| = O\left(\frac{1}{\sqrt{D}}\right) \ w.h.p. \tag{72}$$

Proof.

$$\left|\frac{dist'^2 - \|\mathbf{q}_r - \mathbf{o}_r\|^2}{\|\mathbf{q}_r - \mathbf{o}_r\|^2}\right| = \left|\frac{2\|\mathbf{q}_r - \mathbf{c}\|\|\mathbf{o}_r - \mathbf{c}\|}{\|\mathbf{q}_r - \mathbf{o}_r\|^2}\right| \cdot O\left(\frac{1}{\sqrt{D}}\right) \tag{73}$$

$$= \left|\frac{2\|\mathbf{q}_r - \mathbf{c}\|\|\mathbf{o}_r - \mathbf{c}\|}{\|\mathbf{q}_r - \mathbf{c}\|^2 + \|\mathbf{o}_r - \mathbf{c}\|^2 - 2\langle \mathbf{o}_r - \mathbf{c}, \mathbf{q}_r - \mathbf{c}\rangle}\right| \cdot O\left(\frac{1}{\sqrt{D}}\right) \tag{74}$$

$$= \left|\frac{1}{\frac{1}{2}\left(\frac{\|\mathbf{q}_r - \mathbf{c}\|}{\|\mathbf{o}_r - \mathbf{c}\|} + \frac{\|\mathbf{o}_r - \mathbf{c}\|}{\|\mathbf{q}_r - \mathbf{c}\|}\right) - \langle \mathbf{o}, \mathbf{q}\rangle}\right| \cdot O\left(\frac{1}{\sqrt{D}}\right) \tag{75}$$

$$\leq \left|\frac{1}{1 - \langle \mathbf{o}, \mathbf{q}\rangle}\right| \cdot O\left(\frac{1}{\sqrt{D}}\right) = O\left(\frac{1}{\sqrt{D}}\right) \ w.h.p. \tag{76}$$

其中（73）由（71）得出；（74）通过初等线性代数可得；（75）可简化为（74）。式（76）中的第一个不等式源于等式 $\left(x+\frac{1}{x}\right) \geq 2$，对 $x>0$。公式（76）中的第二个等式成立，是因为**o**服从单位超球面上的均匀分布。特别地，根据集中不等式（引理B.1），$\langle \mathbf{o}, \mathbf{q}\rangle$ 高度集中在 0 附近，例如，它被上界化的概率足够高。$\frac{1}{2}$. □

我们强调，该推论并非完全严格，因为它依赖于**o**服从单位超球面均匀分布的假设。需要注意的是，我们其余所有理论结果均不依赖于对数据的任何假设，即加性界始终成立，而与数据分布无关。在本研究中，我们仅采用一种简单且自然的归一化方法（即基于 IVF 的质心法）来具体实现我们的量化方案，而对于归一化步骤本身，我们尚未开展系统性探索。我们将把对归一化问题的全面且严谨的研究留作未来工作。

为验证当前归一化方法的有效性，我们测量了归一化后数据的经验均匀性[9]。本文采用量化编码中每个比特的熵值作为特征向量。熵值越大，归一化后的数据集分布越均匀（同时，量化编码的信息量也越大）。我们在所有数据集上均观察到：量化编码总长度的熵值占比超过 99.9%（换言之，对于量化编码中的每个比特位，1 与 0 的出现次数几乎相等），这表明采用 IVF 的质心对数据集进行归一化处理在实证中是有效的。

[9]在我们的量化编码中，令p表示整个数据集中第i个比特位中1所占的比例。则第i个比特位的熵等于$-[p\log_2(p) + (1-p)\log_2(1-p)]$。我们报告所有比特位熵值的总和，并将结果除以量化编码的长度，以便于研究。

F 消融研究讨论

我们强调，RaBitQ 是一种具备严格理论保证的方法。新提出的码本构建与距离估计方法构成一个完整体系。若剔除任一组件，都将导致理论保证的丧失（即性能无法在理论上预测），进而使基于误差界的重排序方法在 ANN 中失效（见第4节）。图9详细展示了我们的算法组件与理论结论及高效实现之间的依赖关系：绿色、蓝色与橙色方框分别代表算法中的组件、理论结论及实现部分；箭头表示某特定组件或理论结论被用于实现下游结论或具体实现。此外，我们还需特别说明：尽管 RaBitQ 在最坏情况下的误差界方面达到了渐近最优性，但对于具备特定优良特性的数据集，仍可通过进一步的（可能采用启发式）优化获得更优的实证性能。我们认为这是一个颇具价值的研究课题，并将其列为未来的研究方向。

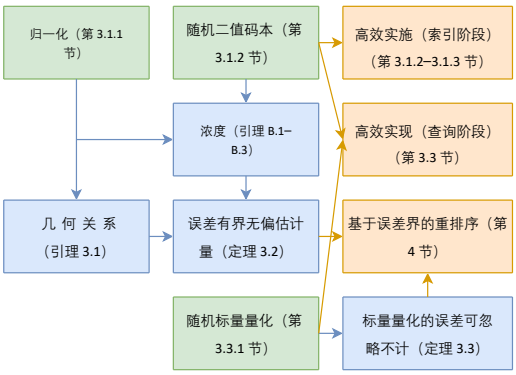


图 9：算法组件、理论结论与高效实现之间的依赖关系

.

尽管从理论角度来看该消融方法并不合理，我们仍提供了若干实证研究，以探讨每个组件在实证层面如何影响模型性能[10]。我们研究了在保留其余组件的前提下，从 RaBitQ 中移除特定组件所产生的影响。

F.1 代码簿构建的消融研究

回顾第3.1节，在对一组归一化数据向量进行量化时，我们通过随机旋转一组二值向量来构建量化码本。本文考虑将随机化码本替换为基于 PQ 学习到的启发式码本，同时保留其他组件。需要指出的是，采用随机化码本时，RaBitQ 具有严格的理论保证，并能实现渐近最优性；而采用学习到的启发式码

[10]需注意的是，若任一组件被剔除，基于误差阈值的重排序方法将被禁用。若将该方法应用于人工神经网络（ANN），则需对重排序过程的参数进行 exhaustive 调优，而这将显著影响 ANN 搜索的结果。因此，在消融研究中，ANN 的结论将缺乏足够的启发性。本文仅报告距离估计的结果。

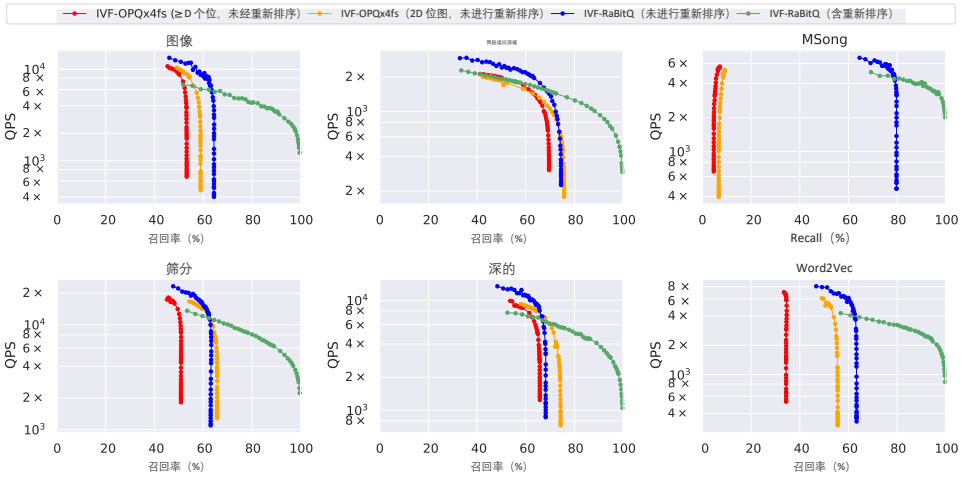


图 10：ANN 搜索的时间-准确率权衡（含与不含重排序）。

本时，该方法的性能则无法再从理论上预测。尽管用学习算法替代随机化算法通常会被认为可提升性能，但在 RaBitQ 中——其设计是一个有机整体——学习得到的码本可能反而不如随机化码本适用。表6展示了在 GIST 数据集上消融实验的平均相对误差与最大相对误差结果，结果清晰表明：用学习得到的码本替代随机化码本，会同时降低距离估计的通用性能与鲁棒性。结果表明，尽管PQ作为一种基于学习的方法，拥有庞大的码本搜索空间，但其启发式学习过程（基于启发式目标函数和近似优化算法）仅在搜索空间中找到次优解。在主要实验（第5.2.1节）中也可观察到类似现象，即 LSQ 的码本搜索空间甚至比PQ更大，但在大多数情况下其性能却较差。

表 6：代码本构建（GIST）的消融研究。

	平均相对误差（%）	最大相对误差（%）
兰德代码手册	1.675	13.043
已学习代码库	3.049	34.375

F.2 估计量的消除

回顾第3.2节所述，与仅将量化数据向量直接视为数据向量的 PQ 方法不同，本方法明确分析了各向量间的几何关系，并据此构建无偏估计量。在本节中，我们
我们摒弃原有估计量，转而采用另一种估计量 $\langle \mathbf{o}, \mathbf{q} \rangle$ ——即像 PQ 方法那样将量化后的数据向量视为原始数据向量。具体而言，我们从 GIST 数据集的前 10 个查询向量及 106 个数据向量中，采集了 107 组估计内积与真实内积的配对数据。图11展示了真实内积与估计内积的散点图，其中红色点代表基于本无偏估计量所得结果。$\frac{\langle \bar{\mathbf{o}}, \mathbf{q} \rangle}{\langle \bar{\mathbf{o}}, \mathbf{o} \rangle}$ 蓝色点表示基于估计量 〈 的结果。$\bar{\mathbf{o}}$, $\mathbf{q}\rangle$ 。我们采用线性回归对这两组数据点进行拟合。结果明确表明，我们的估计量是无偏的，而估计量 $\langle \bar{\mathbf{o}}\mathbf{q}$的偏差比约为 0.8。表7进一步展示了估计值的平均相对误差与最大相对误差。

在 GIST 数据集上进行的距离评估表明，采用 $\langle \mathbf{o}, \mathbf{q} \rangle$ 作为估计量，会同时降低距离估计的通用性能与鲁棒性。此外，我们注意到，基于该估计量 〈$\bar{\mathbf{o}}$对于$\mathbf{q}$，原始理论误差界（定理 3.2）不再成立。因此，该定理不适用于基于误差界的内存 ANN 搜索重排序方法（第4节）。

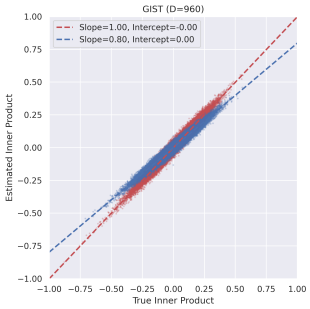


图 11：估计器的消融实验。红色点表示基于该估计量所得的结果$\frac{\langle \bar{\mathbf{o}}, \mathbf{q} \rangle}{\langle \bar{\mathbf{o}}, \mathbf{o} \rangle}$蓝色点表示基于估计量 〈 的结果。$\bar{\mathbf{o}}$, $\mathbf{q}\rangle$.

表 7：估计器（GIST）的消融研究。

	平均相对误差（%）	最大相对误差（%）
$\frac{\langle \bar{\mathbf{o}}, \mathbf{q} \rangle}{\langle \bar{\mathbf{o}}, \mathbf{o} \rangle}$	1.675	13.043
$\langle \bar{\mathbf{o}}, \mathbf{q} \rangle$	2.196	52.400

F.3 重新排序的消除

如第4节所述，尽管RaBitQ提供了距离估计的保证，但当两个不同数据向量到查询点的距离极为接近时，所保证的精度可能不足以正确地对它们进行排序。在这种情况下，重新排序对于实现高召回率是必要的。图10展示了RaBitQ在使用与不使用重新排序时的“QPS”-“召回率”曲线。该图表明，重新排序对于实现ANN搜索的稳健性能确实至关重要。